

解析论文 LaTeX 与 Bib 引用

会话 ID: 019fd10e-8447-7f32-87b7-23e7f160e8dc 开始时间: 2026-08-05 10:34:04 消息数: 36

用户 2026-08-05 10:34:04

Files mentioned by the user:

sources.bib: C:/Users/XiaoyanXiong/Downloads/sources.bib

main.tex: C:/Users/XiaoyanXiong/Downloads/main.tex

My request for Codex:

这是我的论文的latex和bib文件引用。仔细阅读，并详细解析

助手 2026-08-05 10:34:08

我会先完整读取 `main.tex` 和 `sources.bib`，梳理论文结构、研究方法、实验设计，以及正文引用与 BibTeX 条目的对应关系；然后给你一份中文的详细解析，并指出明显的内容、LaTeX 和文献引用问题。只做审阅，不修改原文件。

助手 2026-08-05 10:34:18


文件规模较大（正文约 129 KB、Bib 约 22 KB），我已经确认它是一篇完整的两阶段 NIDS 论文，而不是短稿。现在我在做交叉核查：章节结构、所有引用键、未引用/缺失文献、标签交叉引用、实验数字的一致性，以及方法与结论是否真正互相支撑。

助手 2026-08-05 10:37:23

我已完整审阅 [main.tex](C:/Users/XiaoyanXiong/Downloads/main.tex) 和 [sources.bib](C:/Users/XiaoyanXiong/Downloads/sources.bib)。总体来看，这是一篇结构完整、方法描述较严谨的硕士论文，研究目标明确，实验链条也基本闭合；但目前仍存在若干需要在最终提交前处理的数字一致性、因果性、可复现性和文献元数据问题。

一、论文在研究什么

论文提出一个两阶段、分层的网络入侵检测系统：



核心研究问题是：

- RQ1：包顺序和包间时间是否比单纯的流统计更有判别力？
- RQ2：加入历史关联流以后，能否进一步改善单流分类？

论文的主要创新不是“使用了 Transformer”，而是把网络流量明确划分成两个层次：

1. 包组成流：Stage 1 建模流内部结构；
2. 多个相关流组成主机行为：Stage 2 建模流之间的上下文。

这个研究定位是合理的，也比直接把所有流记录平铺成 Transformer token 更有逻辑。

二、数据集与标签的真实含义

1. 数据来源

论文使用单个企业网络 PCAP：

- 文件大小约 8.62 GB；
- 11,750,727 条包记录；
- 421,898 条流记录；
- 405,254 个标签 0；
- 16,644 个标签 1；
- 正类比例 3.945%；
- 不平衡比约 24.35:1。

数据划分为：

划分	数量	比例
训练集	295,329	70%
验证集	42,189	10%
测试集	84,380	20%

采用按流开始时间排序后的时间划分，而非随机划分。这一点是论文的明显优点，可以降低相邻流量同时进入训练和测试集造成的泄漏。

2. 标签不是人工确认的攻击真值

论文将 Suricata 告警用作标签：

$$y_f = \max_{p_i \in \mathcal{P}_f} y_i^{\{pkt\}}$$

即只要一个 flow 中至少一个包触发 Suricata 告警，该 flow 就标记为 1。

因此：

- 标签 1 的含义是“与 Suricata 告警相关”；
- 标签 0 的含义是“没有观察到 Suricata 告警”；
- 标签 0 不等于经过专家确认的 benign；
- 标签 1 也可能包含 Suricata 误报。

论文已经在 [main.tex:277](C:/Users/XiaoyanXiong/Downloads/main.tex:277) 后明确承认这是 weak label，这是很重要也很诚实的限定。

不过，这会限制论文最强的结论。严格来说，模型证明的是：

- > 它能够学习和预测与当前 Suricata 规则告警相关的流量行为。

而不是直接证明：

- > 它能够发现 Suricata 无法发现的新攻击或零日攻击。

因此, Introduction

中关于“克服规则系统未知攻击局限”的叙述需要保持克制, 否则研究动机与实际标签之间会形成逻辑跳跃。

三、Stage 1 方法解析

Stage 1 负责把一个变长 flow 转换为固定的 128 维表示。

1. 输入

每个 flow 的输入包括:

- 最多 128 个包;
- 每个包的 23 个原始预测字段;
- 包级有效位置 mask;
- flow 内包间到达时间;
- 一组流级统计特征。

包特征主要包括:

- 包长、IP 长度、payload 长度;
- TTL、TCP window、TCP header length;
- IP 版本、协议、ICMP 类型;
- 方向;
- TCP/UDP/ICMP 指示变量;
- TCP flag。

明确排除了:

- IP 地址和端口;
- flow ID、packet ID;
- 绝对时间戳;
- TCP sequence/acknowledgement number;
- `l7\_proto`;
- Suricata 告警和标签。

这套泄漏控制总体合理。

2. 时间表示

论文没有简单地把单个 IAT 当作普通输入字段, 而是先计算:

$$\begin{aligned} & \backslash[\\ T_{\{f,i\}} &= \log(1 + \max(\Delta t_{\{f,i\}}, 0)) \\ & \backslash] \end{aligned}$$

随后形成累积时间坐标, 再与位置编码结合。

这使模型能够区分:

- 相同的包顺序;
- 但发生在不同时间尺度上的通信。

例如, 相同的五个包可能在几毫秒内爆发, 也可能分布在几十秒内; 普通位置编码无法区分, 但累积时间编码可以。

这是 Stage 1 最有说服力的设计之一。

3. 流统计条件化

完整模型 Scheme C 并不是把流统计重复拼接到每一个包后面，而是：

1. 单独编码流统计；
2. 生成 FiLM 风格的 γ, β ；
3. 对包 token 施加有界修正。

形式为：

$$\begin{aligned} & \mathbf{e}_{i,t} \\ &= \tilde{\mathbf{e}}_{i,t} + \lambda_{i,t} \mathbf{r}_{i,t}^{\text{raw}} \end{aligned}$$

并把条件修正限制在原 token 范数的 13% 以内。

此外：

- FiLM 输出层采用零初始化；
- 初始门控约为 $\sigma(-5)=0.0067$ ；
- 模型训练初期近似 packet-only；
- 后续再逐渐学习流统计对包表示的修正。

这个设计可以避免聚合统计在训练初期压倒包序列信息，技术逻辑是清楚的。

4. Transformer 与池化

Stage 1 使用：

- 两层 Transformer；
- 四个 attention heads；
- $d=128$ ；
- FFN 维度 256；
- dropout 0.15；
- 非因果 self-attention。

最后组合三种池化：

- attention pooling；
- mask-aware mean pooling；
- mask-aware max pooling。

因此最终 embedding 同时包含：

- 少量关键包的强信号；
- 整个 flow 的平均行为；
- 局部最大激活。

需要注意：Stage 1 使用完整流或截断后的流，不是在线逐包检测器。论文对此已经明确说明。

四、Stage 2 方法解析

Stage 2 不再读取原始包或流统计，只读取冻结的 Stage 1 embedding。

1. 上下文关系

论文测试四种历史关系：

关系	历史 flow 的选择方式
time-only	全局最近的 flow
source-host	与当前 flow 来源 IP 相同
destination-host	与当前 flow 目的 IP 相同
endpoint	任一端点重合

最终最有效的是 `source\_host`。

2. Target-query attention

与普通 Transformer 对整个窗口执行全 self-attention 不同，论文让：

- 当前 flow 作为唯一 query；
- 历史 flow 作为 key 和 value；
- 历史信息作为当前 flow 的修正，而不是重新编码所有历史 token。

随后组合：

```
\[  
\mathbf{c}_i\mathbf{h}_i;  
\mathbf{c}_i-\mathbf{h}_i;  
\mathbf{c}_i\odot\mathbf{h}_i]  
\]
```

并通过逐维 gate 更新当前表示。

这个设计的优势是：

- 更符合“判断当前 flow”的任务定义；
- 保留当前 flow 的直接残差路径；
- 上下文为空时可以退化为当前流表示；
- attention score 随窗口长度线性增长，而不是完整 $(W \times W)$ self-attention。

3. “因果”定义存在重要限制

Stage 2 只要求：

```
\[  
j<i  
\]
```

也就是历史 flow 的开始时间排序在目标 flow 之前。

但没有要求：

```
\[  
t_j^{\text{end}}\leq t_i^{\text{start}}  
\]
```

因此，一个较早开始、但尚未结束的长 flow，其完整 Stage 1 embedding 可能被用于判断稍后开始的目标 flow。真实在线系统在目标开始时并不一定已经拥有这个历史 embedding。

论文在 [main.tex:1052](C:/Users/XiaoyanXiong/Downloads/main.tex:1052) 已经主动说明这一点。因此最好把方法准确称为：

> start-time-ordered context

而不是不加以限定地称为严格的 online causal context。

这是当前方法最重要的有效性限制之一。

五、实验设计评价

优点

实验控制整体比较规范：

- 时间顺序划分；
- 所有数据依赖型预处理只在训练集拟合；
- 验证 PR-AUC 选择 checkpoint；
- 验证集 class-1 F1 选择阈值；
- 测试集不参与阈值选择；
- weighted sampler 只用于训练；
- embedding 导出时关闭采样；
- Stage 2 统一使用同一个冻结的 Stage 1 checkpoint；
- 重点报告 macro-F1、class-1 F1、PR-AUC、FP、FN 和 FPR。

论文还明确指出名为 `PR-AUC` 的指标实际使用的是：

`average_precision_score`

即 Average Precision，而不是梯形积分 PR-AUC。这个说明很好，但建议全文统一称为：

> Average Precision (AP)

或者首次写作：

> PR-AUC, operationalised as average precision (AP)

之后使用 AP，可避免指标命名争议。

两套测试 manifest

实验实际上使用两套测试集：

- Stage 1 比较：35,410 flows；
- 完整 Scheme C 和 Stage 2：84,380 flows。

论文已经说明不能跨 manifest 做成对比较。但这仍然会增加读者理解难度，尤其是 Scheme C 在不同位置出现非常接近的数值。

建议所有结果图表标题显式标注：

- `Stage-1 controlled manifest, N=35,410`
- `Full chronological manifest, N=84,380`

不要只在实验方法章节说明一次。

六、主要结果应该怎样理解

Stage 1

关键结果为：

模型/方案	Macro-F1	AP/ "PR-AUC"
Flow-statistics MLP	0.7762	0.5604
Packet Transformer, position+time	0.8882	0.8564
完整 Scheme C	约 0.8954–0.8955	0.8763

这表明：

1. 包级顺序和时间信息明显优于仅使用流统计；
2. position 与 elapsed time 互补；
3. 流统计仍然有价值；
4. 但把流统计重复拼到每个包上不是好的融合方式；
5. 单独编码后进行有界条件化取得最好结果。

序列长度实验显示 $(L=128)$ 最好，但论文正确地没有把它表述成普遍规律。

Stage 2

完整测试集结果：

模型	Macro-F1	Class-1 F1	AP/ "PR-AUC"	FPR
Stage 1 Scheme C	0.8954	0.7994	0.8763	0.8249%
Stage 2 source-host	0.9275	0.8610	0.9345	0.5429%

Stage 2 相比独立分类：

- Macro-F1 增加 3.21 个百分点；
- AP 增加 5.82 个百分点；
- 减少 228 个 FP；
- 减少 205 个 FN；
- FPR 相对下降约 34.2%。

由于 FP 和 FN 同时下降，这不是简单调整阈值后用一种错误交换另一种错误，结果具有实际意义。

不过，论文也正确指出：

- no-context MLP 只有 514 个参数；
- proposed Stage 2 有 283,522 个参数；
- 因此 no-context 对照不具备容量匹配；
- 不能把全部提升严格归因于“加入历史”。

一个更强的消融实验应该保留相同 target-query 网络和参数规模，但把历史全部 mask 掉。

七、论文目前最需要修正的问题

1. 摘要与结果的 Stage 1 数字不一致

摘要写的是：

- Macro-F1 = 0.8954。

Stage 1 fusion 部分写的是：

- Macro-F1 = 0.8955。

完整 manifest 表中又是：

- Macro-F1 = 0.8954。

这很可能是两套 manifest 的结果被混合表述。摘要称其为 “controlled Stage 1 flow test manifest”，却使用了更像完整 manifest 的 0.8954。

建议明确统一：

- 若摘要报告完整层级系统共同 manifest：写 0.8954；
- 若报告 Stage 1 controlled manifest：写 0.8955；
- 同时说明对应 \(\mathcal{N}\)。

2. Conclusion 中有排版错误

[main.tex:1659](C:/Users/XiaoyanXiong/Downloads/main.tex:1659) 有：

```
capture.The main contribution
```

`capture.` 后缺少空格，应改为：

```
capture. The main contribution
```

3. 保留了大段注释掉的重复 Conclusions

[main.tex:1661](C:/Users/XiaoyanXiong/Downloads/main.tex:1661)

后保留了一整套旧版结论。虽然不会出现在 PDF

中，但最终提交版本最好删除，避免维护时误恢复或造成版本混淆。

4. “causal/online” 措辞需要统一限定

建议在摘要、贡献列表和结论中避免单独使用：

> causal history / online context

更精确的说法是：

> start-time-ordered, label-free historical context

然后明确指出尚未强制 flow-completion availability。

5. 复现信息严重不足

论文承认没有保留：

- Suricata 精确版本；
- ruleset snapshot；
- Suricata 配置；
- custom module revision；
- PCAP checksum；
- PyTorch 和 scikit-learn 版本；
- 完整 CPU/RAM 信息。

其中最严重的是 ruleset 和 Suricata

版本，因为标签正是由它们产生的。没有这些信息，其他人无法重新生成同一套标签。

即便无法补回，也建议附上目前仍能获得的：

- `custom-out.c` Git commit;
- 训练配置文件;
- pip/conda environment;
- split manifest hash;
- CSV 文件哈希;
- 随机种子 130;
- checkpoint 文件哈希。

6. 固定一个随机种子不能证明结果稳定

所有结论目前来自单次训练。0.16、0.64 个百分点这类小差异不能可靠地区分真实改进和随机波动。

论文已经承认该限制，但注释掉了 “Statistical and External Validation” 整个未来工作小节。建议恢复该小节，至少提出：

- 3–5 个 seeds;
- 均值和标准差;
- paired bootstrap;
- McNemar test;
- aligned prediction comparison。

7. Stage 1 的完整 flow 使用限制在线声明

Stage 1 是非因果的，它可以访问保留下来的整个 flow。若 `head\_tail` 使用最后的包，就更需要等待流结束。

因此本文更准确的部署定位是：

> completed-flow or flow-export-time classification

而不是逐包实时 early detection。

8. 模型提升不能完全归因于 FiLM

Scheme C 同时改变了：

- 是否具有独立 flow branch;
- 参数数量;
- 融合位置;
- FiLM 条件化机制。

因此当前证据只能证明 “Scheme C 整体设计更好”，不能严格证明 “FiLM 本身更好”。论文已经局部承认这一点，建议在贡献和摘要中也避免将增益单独归因于 FiLM。

八、BibTeX 与引用检查结果

自动交叉检查结果：

- 正文引用出现次数：109;
- 正文唯一引用键：52;
- BibTeX 条目：60;
- 缺失引用键：0;
- 重复 BibTeX 键：0;
- 缺失 `label`：0;
- 重复 `label`：0。

也就是说，从 LaTeX 键的对应关系看，引用系统是完整的。

有 8 条文献当前未被正文引用：

- `Alwhbi2024EncryptedSurvey`
- `Garcia2023HighSpeedIDS`
- `Kanimozhi2024MLIDS`
- `Kim2016LSTM`
- `NVIDIAT4Datasheet`
- `Ponniah2023DLIDS`
- `Tan2025ContrastiveSurvey`
- `Zhang2025LLMDetection`

使用传统 BibTeX 时它们通常不会出现在最终参考文献表中，因此不是编译错误；但建议从最终 `.bib` 删除不再需要的条目，减少审阅噪音。

值得人工核验的文献元数据

以下条目存在明显风险：

- `Kim2016LSTM`：键名是 2016，但 `year={2014}`。
- `Ponniah2023DLIDS`：journal 写作 **Journal of Information Security and Applications**，但 DOI 前缀/编号形式看起来可能对应另一刊物，需要核验。
- `Deng2023FlowTopology`：作者字段中的 `Kui Ren Xue` 很可能发生了作者姓名合并或转录错误。
- 多个条目使用 `and others`，这在草稿中可以接受，但最终论文最好提供完整作者，或确保学校的 BibTeX 样式能正确处理。
- `Long2024TransformerNIDS`、部分 2025/2026 条目缺少卷、期、页码或 DOI。
- `SuricataGuide2026`、Google Colab FAQ 等在线文献应包含完整访问日期。
- `MartinReizabal2026FlowWindow` 和 `ElMahdaouy2026ContextNetFlow` 属于很新的文献，应再次核对其正式出版状态、卷期页码和 DOI。
- `Roesch1999` 被同时用于支持 Snort 与 Suricata 相关陈述时要谨慎；Roesch 1999 是 Snort 原始论文，并不能直接支持 Suricata 的具体架构和功能。

此外，Bib 文件仍包含类似：

```
% New entries used by doc/related_work.tex ...
% Additional references used by doc/proposed_methodology.tex.
```

这显然是项目开发阶段的注释，而当前论文已经合并成 `main.tex`。最终版本可以清理。

九、LaTeX 层面的评价

LaTeX 结构总体良好：

- 章节和小节层次清楚；
- 数学公式都有标签；
- 图表引用没有发现缺失标签；
- 使用 `booktabs`、`tabularx`、`longtable`；
- 自定义命令避免字段名排版不一致；
- 图表路径提供了 fallback。

但要注意：

1. `main.tex` 依赖 `mcs.sty`；
2. 依赖 `MScCS/overallFramework.png`；
3. 依赖 `MScCS/ArchitecturalOverview.png`；

4. 依赖 `figures/` 或 `MScCS/figures/` 下多份 PDF;
5. `bibliography{sources}` 要求 `sources.bib` 位于编译工作目录;
6. 单独把这两个 Downloads 文件交给别人, 并不足以完整编译论文。

因此提交时应确保整个 LaTeX 工程一起打包, 而不只是 `main.tex` 和 `sources.bib`。

十、综合评价

这篇论文最强的部分是:

- 研究问题与两阶段架构高度对应;
- 清楚区分流内时间结构与流间上下文;
- 对数据泄漏、类别不平衡、阈值选择有较成熟认识;
- 没有掩盖弱标签、单数据集、单随机种子等限制;
- 结果讨论不仅看 F1, 也分析 FP、FN、FPR 和 AP;
- 对不能下的结论已有较多主动限定。

最主要的风险不是模型设计, 而是:

- Suricata 告警被当作标签导致研究目标受限;
- Stage 2 还不是严格部署时因果;
- 单次运行不足以支持小幅差异;
- 两套测试 manifest 容易引起数字混淆;
- 关键软件和标签生成环境不可复现;
- 部分 BibTeX 元数据可能不准确。

总体上, 它已经接近一篇质量较好的硕士论文, 但在最终提交前, 应优先修正数字一致性、因果措辞、引用元数据和复现信息。

用户 2026-08-05 11:17:32

Files mentioned by the user:

CICIDS2017完全不是公司内部的数据集, 而是网上提供的公共数据集。CICIDS2017 数据集中的Wednesday, July 5, 2017这天的...:

C:\Users\XiaoyanXiong\codex/attachments/d54441bf-a1a9-43e6-a1d0-7138cee86189/pasted-text.txt

My request for Codex:

详细解析

助手 2026-08-05 11:17:37

我会先完整读取你补充的说明, 并把它与论文当前关于“企业内部 proprietary PCAP、真实组织流量、弱标签”的表述逐项对照。重点判断这项更正会影响哪些章节、实验有效性结论, 以及哪些句子必须重写。

助手 2026-08-05 11:17:57

补充材料改变了此前对论文的一个根本判断: CICIDS2017 Wednesday 数据不是公司内部采集, 而是公共基准; 同时你现在实际上已经有两类外部测试——公共跨数据集测试, 以及公司不同服务器的跨环境测试。我也注意到几个会直接影响结果是否能称为“external test”的关键问题, 尤其是各窗口阈值不同, 以及公司测试输出目录中出现了

`leaky\_first\_50`。下面我会把性能和实验有效性分开解析。

助手 2026-08-05 11:19:36

这份补充材料带来了两项重要更正：

1. CICIDS2017 Wednesday-workingHours 是公开数据集，不是公司内部数据；
2. 你已经进行了两种外部测试：
 - 从 `ar002\_et12\_20260511\_001` 迁移到公开 CICIDS2017 Wednesday；
 - 从 `ar002\_et12\_20260511\_001` 迁移到公司另一台服务器的 `firewall\_test\_20250731\_160700`。

从性能数值看，模型表现相当不错；但在写入论文前，必须先确认模型、预处理和阈值是否真正冻结。否则这些结果可能属于目标域再训练或目标域调参，而不能称为严格的 external generalisation。

一、重新界定三个数据集

1. `ar002\_et12\_20260511\_001`

这是源数据集，用于训练 Stage 1 和 Stage 2。

现有论文将其描述为：

- 企业内部流量；
- proprietary PCAP；
- 用于训练、验证和内部时间测试；
- 421,898 flows；
- 正类比例约 3.945%。

如果这些信息正确，这部分不需要改成 CICIDS2017。需要改的是论文中“没有外部测试”的表述。

2. CICIDS2017 Wednesday-workingHours

这是公开 CICIDS2017 数据集中的 Wednesday, July 5, 2017，而不是公司数据。

这一天通常与 DoS/Heartbleed 等流量场景相关。论文中必须引用 CICIDS2017 的原始数据集论文，并准确说明你使用的是：

> CICIDS2017 Wednesday-workingHours PCAP/traffic subset

不能写成：

> company-supplied data、organisational capture 或 proprietary external dataset。

3. `firewall\_test\_20250731\_160700`

这是公司提供的外部数据，但来自完全不同的服务器。

它可以作为：

- cross-server external test；
- cross-environment test；
- second organisational capture；
- same-organisation/different-server generalisation test。

除非能证明采集网络、设备、主机群和规则体系都完全独立，否则不宜直接称为“跨组织测试”。

二、CICIDS2017 五个时间窗口结果

你提供了五个互不重叠、按时间顺序划分的窗口：

- w01;
- w02;
- w06;
- w07;
- w08。

每个窗口正好包含 20,000 flows，因此总共评估了 100,000 flows。

1. 单窗口结果

窗口	正类比例	Macro-F1	Class-1 F1	ROC-AUC	AP/PR-AUC	FP	FN
---	---	---	---	---	---	---	---
w01	18.20%	0.9125	0.8569	0.9816	0.9088	531	513
w02	13.52%	0.9226	0.8663	0.9728	0.9123	383	345
w06	16.48%	0.8536	0.7479	0.9758	0.8906	183	1,218
w07	13.34%	0.8640	0.7651	0.9691	0.8419	710	575
w08	15.24%	0.9220	0.8688	0.9884	0.9397	548	286

五个窗口 Macro-F1 的算术平均值为：

$$\overline{F1}_{\text{macro}} = 0.8949$$

范围为：

$$0.8536 \sim 0.9226$$

这说明模型不是只在某一个偶然窗口上有效，但不同时间段之间存在明显性能波动。

2. 合并 confusion matrix

将五个窗口的 confusion matrix 相加：

$$\begin{bmatrix} \text{TN} & \text{FP} \\ \text{FN} & \text{TP} \end{bmatrix} = \begin{bmatrix} 82,292 & 2,355 \\ 2,937 & 12,416 \end{bmatrix}$$

合并后总样本数为 100,000：

- 负类：84,647;
- 正类：15,353;
- 正类比例：15.353%。

从合并矩阵重新计算：

```
| 指标 | 合并结果 |  
|---|---:|  
| Accuracy | 0.9471 |  
| Macro-precision | 0.9031 |  
| Macro-recall | 0.8904 |  
| Macro-F1 | 0.8966 |  
| Class-1 precision | 0.8406 |  
| Class-1 recall | 0.8087 |  
| Class-1 F1 | 0.8243 |  
| FPR | 2.7821% |  
| FNR | 19.1298% |
```

注意：AP 和 ROC-AUC 不能只通过 confusion matrix 合并。要得到整个 100,000-flow 测试集的总体 AP/ROC-AUC，需要保存并合并每个 flow 的真实标签和预测概率，再重新计算。

不能简单平均窗口 AP 后称为总体 AP。

三、各窗口说明了什么

w01：表现均衡

w01 的结果：

- Macro-F1: 0.9125;
- Class-1 precision: 0.8548;
- Class-1 recall: 0.8590;
- AP: 0.9088;
- FP/FN: 531/513。

precision 与 recall 非常接近，说明该窗口的决策点比较平衡。模型没有明显偏向保守或激进预测。

w02：最好的综合窗口之一

w02：

- Macro-F1: 0.9226，为五个窗口最高；
- Class-1 F1: 0.8663；
- FP: 383；
- FN: 345。

它的 ROC-AUC 低于 w01，但 F1 更高，说明：

- 模型的整体排序能力不是最高；
- 但当前阈值附近的分类边界更合适。

这再次表明不能只看 ROC-AUC。

w06：排序很好，但正类召回明显下降

w06：

- ROC-AUC: 0.9758;
- AP: 0.8906;
- Class-1 precision: 0.9191;

- Class-1 recall: 0.6305;
- FP 只有 183;
- FN 高达 1,218。

这是最典型的保守型工作点:

- 一旦模型判为攻击, 通常比较可靠;
- 但漏掉了约 37% 的正类;
- Class-1 F1 因此下降到 0.7479。

w06 的问题不主要是模型完全不会排序, 因为 ROC-AUC 和 AP 仍然较高。更可能是:

1. 阈值不适合这个窗口;
2. 该时间段正类概率整体向低分移动;
3. 正类攻击类型或流量结构发生变化;
4. 源数据与这个时间段存在显著 domain shift;
5. source-host 上下文在该窗口覆盖不足。

如果使用源域固定阈值, 这可以作为真实 temporal domain shift 的证据; 如果阈值由 w06 自身标签选出, 则即使调参后 recall 仍低, 问题就更值得分析。

w07: 误报明显增加

w07:

- Macro-F1: 0.8640;
- AP: 0.8419, 为五个窗口最低;
- Class-1 precision: 0.7467;
- recall: 0.7845;
- FP: 710, 为五个窗口最高。

这说明 w07 不只是阈值位置不理想, 其排序能力本身也发生下降。可能原因包括:

- 正负类的特征分布更接近;
- 该段 benign 流量与源域中的 alert-associated 流量相似;
- CICIDS 主机身份和流关系与源数据不同;
- source-host 历史混入大量无关连接;
- 标签映射或字段转换在该窗口不一致。

w06 与 w07 的退化机制不同:

- w06 主要表现为高 FN、低 FP;
- w07 主要表现为高 FP 和较低 AP。

论文中不应只报告平均 Macro-F1, 而应突出这种窗口间差异。

w08: 正类召回最好

w08:

- Macro-F1: 0.9220;
- AP: 0.9397, 为五个窗口最高;
- Class-1 recall: 0.9061, 为五个窗口最高;
- Class-1 F1: 0.8688, 为五个窗口最高;
- FN 只有 286。

w08 表明模型在某些外部时段可以同时保持较高排序能力和攻击召回率。它支持模型学到了一部分可迁移的行为特征，而不只是记住源数据中的具体流量比例。

但单独使用 w08 会过度乐观；五个窗口必须一起报告。

四、CICIDS2017 结果与内部测试的比较

论文内部完整测试结果是：

测试	Macro-F1	Class-1 F1	AP	FPR
源数据内部时间测试	0.9275	0.8610	0.9345	0.5429%
CICIDS 五窗口合并	0.8966	0.8243	无法由现有摘要合并	2.7821%

从表面看，迁移到 CICIDS2017 后：

- Macro-F1 下降约 3.09 个百分点；
- Class-1 F1 下降约 3.67 个百分点；
- FPR 从约 0.54% 增加到约 2.78%。

但这个比较必须谨慎，因为：

- 源测试集正类比例为约 4.17%；
- CICIDS 五窗口正类比例为 15.35%；
- 数据采集与标签生成方式可能不同；
- threshold 可能不同；
- 流特征提取管线可能不同。

因此不能把差异全部解释为泛化下降。

即便如此，如果确实是完全冻结的外部测试，Macro-F1 仍接近 0.90，说明迁移表现是有价值的。更准确的结论是：

> Performance declined moderately and varied across chronological CICIDS2017 windows, but the detector retained substantial discrimination on a public dataset collected in a different environment.

而不是：

> The model generalises universally across networks.

五、公司不同服务器外部测试

`firewall\_test\_20250731\_160700` 的结果：

- 样本数：38,513；
- 正类：1,265；
- 正类比例：3.285%；
- TN：37,087；
- FP：161；
- FN：292；
- TP：973。

指标：


```
| 指标 | 结果 |
|---|---|
| Accuracy | 0.9882 |
| Macro-precision | 0.9251 |
| Macro-recall | 0.8824 |
| Macro-F1 | 0.9026 |
| Class-1 precision | 0.8580 |
| Class-1 recall | 0.7692 |
| Class-1 F1 | 0.8112 |
| ROC-AUC | 0.9870 |
| AP | 0.8771 |
| FPR |  $\frac{161}{(37087+161)}=0.4322\%$  |
| FNR |  $\frac{292}{(292+973)}=23.083\%$  |
```

结果含义

这个测试集与源数据的正类比例非常接近：

- 源原始数据：3.945%；
- 外部服务器：3.285%。

因此它与源内部测试比 CICIDS2017 更可比。

主要特点是：

- FPR 很低，仅约 0.43%；
- 正类 precision 较高，为 0.858；
- recall 只有 0.769；
- 模型比较保守；
- 292 个攻击相关 flow 被漏掉。

与内部测试相比：

- Macro-F1 从 0.9275 降到 0.9026；
- Class-1 F1 从 0.8610 降到 0.8112；
- AP 从 0.9345 降到 0.8771；
- FPR 反而从 0.5429% 降到约 0.4322%；
- 主要退化来自 FN 增加，而不是 FP 增加。

因此，这个跨服务器结果说明：

- > 模型在另一服务器上仍保持较好的精度和很低的误报率，但攻击召回出现下降。

这是典型的跨环境分布变化表现。

六、目前最严重的实验有效性问题

1. 五个 CICIDS 窗口使用了不同阈值

你提供的阈值分别为：

- w01: 0.5693；
- w02: 0.4604；
- w06: 0.4852；
- w07: 0.5000；

- w08: 0.5099。

如果这五个窗口都是纯 external test，阈值原则上应该相同，且应当来自：

> `ar002\_et12\_20260511\_001` 的 validation set。

外部测试集不能使用自己的真实标签重新选择最佳阈值，否则目标域标签参与了模型决策规则的制定。

如果每个窗口的 threshold 是根据该窗口内部标签优化出来的，那么这些结果属于：

- target-domain threshold calibration;
- adapted external evaluation;
- 或 oracle-threshold evaluation;

而不是严格的零样本 external test。

必须查清阈值来自哪里。

可能存在两种情况：

情况 A：阈值来自各自的外部 validation portion

那么每个 “external-test pair” 可能包含：

- 一个目标域验证窗口；
- 一个随后目标域测试窗口。

这种设计可以成立，但应称为：

> chronologically calibrated target-domain evaluation

而不是完全冻结的 external test。

情况 B：阈值直接通过当前 test window 的标签选择

这是测试泄漏，相关 threshold-dependent 指标不能作为正式结果。

此时：

- Accuracy;
- Macro-F1;
- confusion matrix;
- FP/FN/FPR;

都会被目标测试标签影响。

但 ROC-AUC 和 AP 不依赖最终分类阈值，仍可保留作为排序能力证据，前提是模型权重没有使用测试数据训练。

2. `run\_stage2.py --epochs 500` 可能重新训练了 Stage 2

外部测试命令中使用了：

```
run_stage2.py
--epochs 500
```

这看起来不像单纯加载冻结模型进行推理，而像是在每个外部数据对上训练 Stage 2。

必须检查 `run\_stage2.py`：

- 是否加载源域 Stage 2 checkpoint;
- 是否从头训练 Stage 2;
- Stage 2 的训练 split 来自哪里;

- 外部窗口是否进入训练;
- 是否只冻结 Stage 1, 但重新训练 Stage 2。

如果 Stage 2 在 CICIDS2017 上训练了, 就不能说:

> trained on ar002 and externally tested on CICIDS2017。

更准确的是:

> Stage 1 transferred from ar002, while Stage 2 was trained or adapted on CICIDS2017 embeddings。

这两者代表完全不同的泛化强度。

3. `leaky\_first\_50` 是明显警告

公司外部测试输出目录写着:

```
B_external_firewall_test_20250731_160700_leaky_first_50
```

其中 `leaky` 很可能是你或代码作者已经标记出的数据泄漏版本。

在没有弄清 `leaky\_first\_50` 的具体含义前, 这组结果不能直接写入论文作为外部验证证据。

需要检查:

- “first 50” 指前 50% 用于训练吗?
- 训练历史是否包含测试流?
- 是否先构造完整 context 再切分?
- 预处理器是否在整个 firewall 数据上 fit?
- threshold 是否由 firewall test labels 选择?
- Stage 2 是否在 firewall 数据上重新训练?

如果确认存在泄漏, 这组结果应当废弃并重新运行。

七、外部测试的正确等级划分

建议根据实际流程, 把结果划分为以下三种之一。

等级 1: 严格冻结外部测试

要求:

- Stage 1 权重冻结;
- Stage 2 权重冻结;
- preprocessing 只在源训练集 fit;
- category vocabulary 不使用外部数据;
- 阈值来自源验证集;
- 外部标签只用于最终评估;
- 不使用外部数据 early stopping;
- 不使用外部数据选择窗口或模型。

这是最强的 external generalisation。

等级 2: 目标域无标签适配

允许:

- 使用目标域无标签数据校准统计量或构造 context;
- 不能使用目标域标签训练模型或选择阈值。

必须明确称为 unsupervised domain adaptation, 而不是纯冻结测试。

等级 3: 目标域监督微调/校准

允许:

- 使用外部训练或验证标签;
- 重新训练 Stage 2;
- 选择目标域阈值。

这可以研究迁移学习, 但应称为:

- transfer learning;
- supervised adaptation;
- chronologically calibrated evaluation.

不能与等级 1 的 frozen external test 混在一起。

八、论文现在需要怎样改

原论文中的以下结论已经过时:

> variation across training runs and external generalisation have yet to be established.

应根据审计后的实验类型改写。

如果确认是严格冻结测试, 可以改成:

> External evaluation was additionally conducted on five non-overlapping chronological windows from the public CICIDS2017 Wednesday capture and on a separate company-provided capture obtained from a different server. Performance remained substantial, although variation across windows and reduced positive-class recall indicate sensitivity to domain and temporal shift.

Dataset 部分应该新增一个小节:

```
\section{External Evaluation Datasets}
```

分别介绍:

1. Source enterprise dataset;
2. Public CICIDS2017 Wednesday dataset;
3. Company cross-server dataset.

Results 中新增:

```
\section{External Generalisation}
\subsection{Public Cross-Dataset Evaluation}
\subsection{Cross-Server Organisational Evaluation}
\subsection{Temporal and Domain-Shift Analysis}
```

并明确报告:

- 样本数;
- 正类比例;
- 是否重新训练;
- checkpoint 来源;

- preprocessing 来源;
- threshold 来源;
- context 是否跨窗口延续;
- 每窗口 confusion matrix;
- 合并 confusion matrix;
- 概率级总体 AP/ROC-AUC。

九、当前可以得出的结论

在暂时假定模型和预处理没有使用外部测试标签训练的情况下，结果表明：

1. 模型在 CICIDS2017 的 100,000 个外部 flows 上保持了约 0.8966 的 pooled Macro-F1;
2. 外部窗口性能存在明显波动，Macro-F1 从 0.8536 到 0.9226;
3. w06 主要问题是漏报，w07 主要问题是误报和排序下降;
4. 在公司不同服务器数据上，模型达到 0.9026 Macro-F1 和约 0.432% FPR;
5. 跨服务器退化主要表现为正类 recall 降低;
6. 这些结果支持存在一定可迁移性，但不能证明普遍泛化;
7. 是否能正式称为 external test，取决于 Stage 2 是否重新训练、阈值来源及 `leaky\_first\_50` 的真实含义。

目前最优先的工作不是马上把这些漂亮数字加入论文，而是审计外部测试管线。尤其需要确认：

- `run\_stage2.py` 在外部数据上究竟是训练还是推理;
- 五个不同 threshold 是怎样产生的;
- `leaky\_first\_50` 泄漏了什么;
- Stage 1 和 Stage 2 的 checkpoint 是否都来自源数据;
- 外部测试的 scaler、encoder vocabulary 是否仍来自源训练集。

用户 2026-08-05 11:33:40

CICIDS2017完全不是公司内部的数据集，而是网上提供的公共数据集。

CICIDS2017 数据集的Wednesday, July 5, 2017这天的数据集 (Wednesday-workingHours) Create multiple non-overlapping, chronological Stage1 external-test pairs. flows_per_window = 20000
ar002_et12_20260511_001这个数据集用于训练和Wednesday-workingHours这个数据集用于外部测试,看运行结果

external_Wednesday_workingHour_w01

```
[TEST] Full metrics: {'accuracy': 0.9478, 'macro_precision': 0.9117047149155886, 'macro_recall': 0.9132859881890929, 'macro_f1': 0.912492597074879, 'weighted_precision': 0.9479024302587923, 'weighted_recall': 0.9478, 'weighted_f1': 0.9478500262321042, 'precision_label1': 0.8547990155865464, 'recall_label1': 0.8590272052761748, 'f1_label1': 0.8569078947368421, 'auc': 0.9816462109649925, 'pr_auc': 0.9088162432022562, 'per_class_f1': {'0': 0.9680772994129159, '1': 0.8569078947368421}, 'confusion_matrix': [[15830, 531], [513, 3126]], 'num_classes': 2, 'num_samples': 20000, 'loss': 0.08718816034980119, 'positive_count': 3639, 'positive_rate': 0.18195}
```

external_Wednesday_workingHour_w02

```
[TEST] Full metrics: {'accuracy': 0.9636, 'macro_precision': 0.9201402019015443, 'macro_recall': 0.9251107359401081, 'macro_f1': 0.9226037723941944, 'weighted_precision': 0.9638275068642708, 'weighted_recall': 0.9636, 'weighted_f1': 0.9637070250514578, 'precision_label1': 0.8602699744618753, 'recall_label1': 0.8723640399556049, 'f1_label1': 0.8662747979426892, 'auc': 0.9728137874423917, 'pr_auc': 0.9123266972816622, 'per_class_f1': {'0': 0.9789327468456998, '1': 0.8662747979426892},
```

```
'confusion_matrix': [[16914, 383], [345, 2358]], 'num_classes': 2, 'num_samples': 20000, 'loss': 0.08845344604994171, 'positive_count': 2703, 'positive_rate': 0.13515}
```

external_Wednesday_workingHour_w06

```
[TEST] Full metrics: {'accuracy': 0.92995, 'macro_precision': 0.9252000461056542, 'macro_recall': 0.8097528526392144, 'macro_f1': 0.8536048252225783, 'weighted_precision': 0.9293147496730008, 'weighted_recall': 0.92995, 'weighted_f1': 0.9244790274946596, 'precision_label1': 0.91906236178682, 'recall_label1': 0.6304611650485437, 'f1_label1': 0.7478855497570631, 'auc': 0.9758162650129729, 'pr_auc': 0.890644232039029, 'per_class_f1': {'0': 0.9593241006880934, '1': 0.7478855497570631}, 'confusion_matrix': [[16521, 183], [1218, 2078]], 'num_classes': 2, 'num_samples': 20000, 'loss': 0.08560779412984848, 'positive_count': 3296, 'positive_rate': 0.1648}
```

external_Wednesday_workingHour_w07

```
[TEST] Full metrics: {'accuracy': 0.93575, 'macro_precision': 0.856631949947048, 'macro_recall': 0.8717590345145914, 'macro_f1': 0.8639550555357431, 'weighted_precision': 0.937234081805912, 'weighted_recall': 0.93575, 'weighted_f1': 0.9364171014868657, 'precision_label1': 0.7466999643239386, 'recall_label1': 0.7844827586206896, 'f1_label1': 0.7651252056296838, 'auc': 0.96909518570394, 'pr_auc': 0.8419498323922726, 'per_class_f1': {'0': 0.9627849054418025, '1': 0.7651252056296838}, 'confusion_matrix': [[16622, 710], [575, 2093]], 'num_classes': 2, 'num_samples': 20000, 'loss': 0.07822086189687252, 'positive_count': 2668, 'positive_rate': 0.1334}
```

external_Wednesday_workingHour_w08

```
[TEST] Full metrics: {'accuracy': 0.9583, 'macro_precision': 0.9086280358871877, 'macro_recall': 0.936906260906933, 'macro_f1': 0.9219982163966258, 'weighted_precision': 0.9602450089071224, 'weighted_recall': 0.9583, 'weighted_f1': 0.9589970878997421, 'precision_label1': 0.834391054699305, 'recall_label1': 0.9061371841155235, 'f1_label1': 0.868785399622404, 'auc': 0.9883564555230605, 'pr_auc': 0.9396812887460526, 'per_class_f1': {'0': 0.9752110331708477, '1': 0.868785399622404}, 'confusion_matrix': [[16405, 548], [286, 2761]], 'num_classes': 2, 'num_samples': 20000, 'loss': 0.06357301649544388, 'positive_count': 3047, 'positive_rate': 0.15235}
```

firewall_test_20250731_160700这个数据集是公司提供的，但是从完全不同的服务器上后取得数据
ar002_et12_20260511_001这个数据集用于训练和firewall_test_20250731_160700这个数据集用于外部测试,看运行结果

external_firewall_test_20250731_160700

```
[TEST] Full metrics: {'accuracy': 0.9882377379066809, 'macro_precision': 0.9251064091906098, 'macro_recall': 0.8824237903746113, 'macro_f1': 0.9025505661551252, 'weighted_precision': 0.9877813878411928, 'weighted_recall': 0.9882377379066809, 'weighted_f1': 0.9879269160785962, 'precision_label1': 0.8580246913580247, 'recall_label1': 0.7691699604743083, 'f1_label1': 0.81117132138391, 'auc': 0.9869553544748246, 'pr_auc': 0.8771333736541826, 'per_class_f1': {'0': 0.9939298109263404, '1': 0.81117132138391}, 'confusion_matrix': [[37087, 161], [292, 973]], 'num_classes': 2, 'num_samples': 38513, 'loss': 0.02039551498781868, 'positive_count': 1265, 'positive_rate': 0.032846051982447486}
```

助手 2026-08-05 11:35:43

你的实验现在包含两个性质不同、互相补充的外部测试：

1. 公共跨数据集测试：

用公司数据集 `ar002\_et12\_20260511\_001` 训练，在公开的 CICIDS2017 Wednesday-workingHours 上测试。

2. 公司跨服务器测试：

同样用 `ar002\_et12\_20260511\_001` 训练，在公司另一台完全不同服务器采集的

`firewall\_test\_20250731\_160700` 上测试。

如果 Stage 1、Stage 2、预处理参数和分类阈值都只由源数据确定，并且外部标签仅用于最后计算指标，那么这些结果构成了比原论文“单一企业捕获内部测试”更强的外部泛化证据。

一、数据集角色必须先明确

| 数据集 | 属性 | 实验角色 |

|---|---|---|

| `ar002\_et12\_20260511\_001` | 公司内部数据 | 训练、验证和源域内部测试 |

| CICIDS2017 Wednesday-workingHours | 公开基准数据 | 公共跨数据集外部测试 |

| `firewall\_test\_20250731\_160700` | 公司提供、不同服务器采集 | 公司跨服务器外部测试 |

CICIDS2017 不能被称为：

- company-provided dataset;
- proprietary organisational capture;
- another company server capture.

应称为：

> the publicly available CICIDS2017 Wednesday-workingHours capture

公司 firewall 数据则可以称为：

> a separate company-provided capture collected from a different server environment

“不同服务器”不一定等于“不同组织”，因此最稳妥的术语是：

- cross-server generalisation;
- cross-environment organisational evaluation;
- second organisational capture.

二、CICIDS2017 五个窗口的总体结果

五个窗口均包含 20,000 flows，总计：

\[

$N=100,000$

\]

将五个 confusion matrix 相加得到：

\[

$\begin{bmatrix}$

TN & FP\\

FN & TP

$\end{bmatrix}$

=

$\begin{bmatrix}$

82,292 & 2,355\\

2,937 & 12,416

$\end{bmatrix}$

\]

因此：

- 总负类：84,647；
- 总正类：15,353；
- 总正类比例：15.353%；
- 正确预测：94,708；
- 错误预测：5,292。

由合并矩阵计算得到：

```
| 指标 | 合并结果 |
|---|---|
| Accuracy | 0.9471 |
| Macro-precision | 0.9031 |
| Macro-recall | 0.8904 |
| Macro-F1 | 0.8966 |
| Class-1 precision | 0.8406 |
| Class-1 recall | 0.8087 |
| Class-1 F1 | 0.8243 |
| Class-0 F1 | 0.9688 |
| FPR | 2.7821% |
| FNR | 19.1298% |
```

五个窗口 Macro-F1 的简单平均为：

```
\[
\frac{0.9125+0.9226+0.8536+0.8640+0.9220}{5}
=0.8949
\]
```

这个数与 pooled Macro-F1 的 0.8966 不完全相同，因为：

- 0.8949 是五个窗口指标的算术平均；
- 0.8966 是先合并所有 confusion matrix，再重新计算。

论文中建议把 0.8966 作为总体 pooled Macro-F1，同时报告窗口均值和范围：

```
\[
\text{mean}=0.8949,\quad
\text{range}=0.8536\text{--}0.9226
\]
```

三、五个 CICIDS2017 窗口对比

```
| 窗口 | 正类比例 | Accuracy | Macro-F1 | Class-1 F1 | ROC-AUC | AP/PR-AUC | FP | FN |
|---|---|---|---|---|---|---|---|---|
| w01 | 18.20% | 0.9478 | 0.9125 | 0.8569 | 0.9816 | 0.9088 | 531 | 513 |
| w02 | 13.52% | 0.9636 | **0.9226** | 0.8663 | 0.9728 | 0.9123 | 383 | 345 |
| w06 | 16.48% | 0.9300 | 0.8536 | 0.7479 | 0.9758 | 0.8906 | **183** | **1,218** |
| w07 | 13.34% | 0.9358 | 0.8640 | 0.7651 | 0.9691 | 0.8419 | **710** | 575 |
| w08 | 15.24% | 0.9583 | 0.9220 | **0.8688** | **0.9884** | **0.9397** | 548 | **286** |
```

从结果看，外部性能并不是均匀的。不同时间窗口存在明显的 temporal/domain variation。

四、逐窗口详细解释

1. w01: 精确率与召回率最平衡

w01:

- Class-1 precision: 0.8548;
- Class-1 recall: 0.8590;
- Class-1 F1: 0.8569;
- FP: 531;
- FN: 513。

precision 和 recall 几乎相等，表明该窗口的工作点非常均衡。模型既没有明显过度告警，也没有明显过度保守。

其 Macro-F1 为 0.9125，AP 为 0.9088，说明：

- 阈值下的分类表现较好；
- 阈值无关的正类排序能力也较好；
- 结果不是单纯由类别比例或某一个有利阈值产生的。

这是一个比较稳定的外部测试窗口。

2. w02: 综合 Macro-F1 最好

w02 的 Macro-F1 为 0.9226，是五个窗口最高值；Class-1 F1 为 0.8663。

错误数量也较低：

- FP: 383;
- FN: 345。

值得注意的是，w02 的 ROC-AUC 为 0.9728，低于 w01，但 Macro-F1 更高。这说明 ROC-AUC 和最终分类表现测量的是不同性质：

- ROC-AUC 衡量所有可能阈值下的整体排序；
- Macro-F1 衡量当前固定工作点的分类效果。

因此不能根据 ROC-AUC 单独决定哪个窗口“最好”。

w02 的表现说明当前决策边界对这一时段的数据分布很合适。

3. w06: 高精确率、严重漏报

w06 是最值得分析的窗口：

- Class-1 precision: 0.9191;
- Class-1 recall: 0.6305;
- FP: 183;
- FN: 1,218;
- ROC-AUC: 0.9758;
- AP: 0.8906。

模型在 w06 非常保守：

> 一旦预测为正类，通常是正确的；但大量真正的正类没有被预测出来。

正类漏报率为：

```
\[
1-0.63046=36.9539\%
\]
```

也就是说，超过三分之一的正类被漏掉。

但其 ROC-AUC 和 AP 并不低。这意味着模型并没有完全失去区分正负样本的能力，更可能出现：

- 外部正类概率整体下移；
- 固定阈值对该窗口偏高；
- 正类行为与训练集正类存在分布差异；
- 该时段包含模型不熟悉的攻击子类型；
- Stage 2 的 source-host 上下文对这一时段覆盖不足。

若阈值完全由源域验证集确定，那么 w06 是很有价值的结果：它真实揭示了跨数据集部署时的 calibration/domain-shift 问题。

不能因为 Macro-F1 较低就删除这个窗口。相反，它是外部测试存在价值的重要证据。

4. w07：误报增加且排序能力下降

w07：

- Class-1 precision: 0.7467;
- Class-1 recall: 0.7845;
- FP: 710;
- FN: 575;
- AP: 0.8419, 为五个窗口最低。

w07 与 w06 的退化方式明显不同：

- w06：主要是漏报；
- w07：主要是误报增加，同时 AP 下降。

w07 中的负类可能在特征空间上更像训练数据中的告警流量，或者 source-host 历史中混入了更多容易产生误判的连接。

因为 AP 也下降，所以这不只是阈值问题。它说明模型在这个窗口中对正负类的排序分离能力确实变弱。

这可以支持论文中的一个重要结论：

> 外部泛化不仅受数据集整体差异影响，也会随同一外部捕获中的时间窗口而变化。

5. w08：外部表现最强的窗口

w08：

- Class-1 recall: 0.9061;
- Class-1 F1: 0.8688;
- ROC-AUC: 0.9884;
- AP: 0.9397;
- FN: 286。

这是五个窗口中：

- AP 最高；
- ROC-AUC 最高；
- Class-1 F1 最高；

- 正类召回最高;
- FN 最少。

它说明模型在某些外部时间段中能够很好地识别攻击相关行为。模型并非只能适应公司源数据，确实学到了一部分可以跨数据集迁移的特征。

但论文不能只引用 w08，因为它是最有利窗口。必须同时报告全部预先确定的窗口。

五、为什么 Accuracy 不应作为主要结论

CICIDS 五窗口的正类比例约为 13%–18%，比公司源数据约 4% 高。因此 Accuracy 比在源数据中更有意义一些，但仍然不能取代正类指标。

例如 w06:

- Accuracy: 92.995%;
- ROC-AUC: 97.58%;
- 但 Class-1 recall 只有 63.05%。

如果只报告 Accuracy 或 ROC-AUC，读者可能误以为检测性能非常稳定；实际上它漏掉了 1,218 个正类。

所以你的论文应继续以以下指标为主：

- Macro-F1;
- Class-1 precision、recall 和 F1;
- AP;
- FP、FN;
- FPR、FNR。

六、外部测试的 AP 应怎样报告

你当前每个窗口的 ``pr_auc`` 实际上应与原论文保持相同定义，即：

```
average_precision_score
```

因此更精确的名称是 Average Precision，简称 AP。

五个窗口 AP 分别为：

```
\[
0.9088,\ 0.9123,\ 0.8906,\ 0.8419,\ 0.9397
\]
```

简单平均为：

```
\[
\overline{AP}\approx0.8987
\]
```

但这个 0.8987 只能称为：

> mean window-level AP

不能称为 100,000 flows 的 pooled AP。

要得到总体 pooled AP，应合并五个窗口的：

- `y\_true`;
- 正类预测概率 `y\_score`;

然后重新运行:

```
average_precision_score(y_true_all, y_score_all)
roc_auc_score(y_true_all, y_score_all)
```

由于 AUC 和 AP 是基于预测分数排序计算的, 单凭 confusion matrix 无法恢复总体结果。

七、公司不同服务器测试结果

公司外部服务器数据包含:

- 38,513 flows;
- 37,248 个负类;
- 1,265 个正类;
- 正类比例 3.285%。

Confusion matrix:

```
\[
\begin{bmatrix}
37,087 & 161 \\
292 & 973
\end{bmatrix}
\]
```

主要结果

指标	数值
Accuracy	0.9882
Macro-precision	0.9251
Macro-recall	0.8824
Macro-F1	0.9026
Class-1 precision	0.8580
Class-1 recall	0.7692
Class-1 F1	0.8112
ROC-AUC	0.9870
AP	0.8771
FP	161
FN	292
FPR	0.4322%
FNR	23.0830%

1. 非常低的误报率

```
\[
FPR=\frac{161}{37,087+161}=0.4322\%
\]
```

这比论文内部测试的 0.5429% 还低。

从运营角度看, 这是一个积极结果: 模型迁移到另一台服务器后, 没有出现大规模误报爆发。

2. 主要退化来自漏报

Class-1 recall 为 0.7692, 意味着:

```
\[
FNR=1-0.7692=23.08\%
\]
```

模型漏掉了接近四分之一的正类。与内部测试相比, 跨服务器后的主要问题是 recall 降低, 而不是 precision 或 FPR 恶化。

换言之, 模型表现为:

> 高置信、低误报, 但在新服务器上偏保守。

3. 排序能力仍然很强

ROC-AUC 为 0.9870, AP 为 0.8771, 说明模型仍能较好地地区分正负样本。

高 AUC/AP 与较低 recall 同时出现, 通常提示:

- 模型仍有区分能力;
- 但概率校准或固定阈值未必适配新环境。

不过, 不能为了提高外部测试结果而直接用该外部测试标签重新调阈值。更规范的做法是:

- 保持源验证阈值不变, 报告严格冻结结果;
- 另做一项独立的 threshold/calibration sensitivity analysis;
- 清楚区分 frozen result 和 adapted result。

八、与论文内部结果比较

论文中完整模型的内部测试结果:

测试环境	Macro-F1	Class-1 F1	ROC-AUC	AP	FPR
源域内部时间测试	0.9275	0.8610	0.9938	0.9345	0.5429%
CICIDS 五窗口 pooled	0.8966	0.8243	需合并概率计算	需合并概率计算	2.7821%
公司不同服务器	0.9026	0.8112	0.9870	0.8771	0.4322%

1. 公共跨数据集测试

相对内部结果:

- Macro-F1 下降约 3.09 个百分点;
- Class-1 F1 下降约 3.67 个百分点;
- FPR 增加约 2.24 个百分点。

这是合理的跨数据集退化, 因为 CICIDS2017 与源数据在以下方面可能都不同:

- 采集网络;
- 主机和服务;
- 攻击场景;
- 正类比例;
- 流构建方式;
- 标签来源;
- 时间结构;

- source-host 行为模式。

在这种差异下仍保持接近 0.90 的 pooled Macro-F1，是有价值的泛化结果。

2. 公司跨服务器测试

相对内部结果：

- Macro-F1 下降约 2.49 个百分点；
- Class-1 F1 下降约 4.98 个百分点；
- AP 下降约 5.74 个百分点；
- FPR 没有上升，反而略有下降。

这说明跨服务器迁移比 CICIDS2017 更接近源环境，但模型依然发生了正类召回退化。

3. 为什么不能直接根据数值判断哪个外部数据更容易

CICIDS pooled Class-1 F1 高于公司外部服务器：

- CICIDS: 0.8243；
- 公司服务器: 0.8112。

但不能简单得出“公共数据比公司服务器更容易”，因为两者正类比例差异很大：

- CICIDS: 15.353%；
- firewall: 3.285%。

类别比例会显著影响 precision、AP、F1 和阈值行为。更有意义的比较需要同时考虑：

- ROC-AUC；
- FPR；
- recall；
- 正类比例；
- 固定阈值；
- 标签定义是否一致。

九、Stage 2 的 source-host 上下文在外部数据上的含义

这些外部结果不仅测试 Stage 1 表示，也测试 Stage 2 的关系假设是否能迁移。

源数据中最有效的关系是：

source_host

即当前 flow 查询同一来源主机的历史 flows。

在 CICIDS2017 和另一服务器上仍获得较高指标，说明 source-host relation 可能捕捉到了部分跨环境稳定行为，例如：

- 同一来源的重复连接；
- 扫描；
- 重试模式；
- 多目标访问；
- 短期连接爆发；
- 相似的恶意通信序列。

但窗口波动说明这一关系并非始终稳定：

- w06 可能缺少足够有效的同源历史;
- w07 可能把大量正常同源活动纳入上下文;
- 不同数据集中的 NAT、共享服务器和主机角色可能改变 source-host 的语义。

因此结论应是:

> Source-host context transferred usefully across the evaluated external datasets, but its benefit varied across chronological windows.

而不是:

> Source-host is universally the best context relation.

十、外部测试成立所需的实验条件

要在论文中正式使用 “external generalisation” , 应明确记录以下内容。

必须冻结的内容

外部测试期间应冻结:

- Stage 1 checkpoint;
- Stage 2 checkpoint;
- numerical clipping limits;
- median/IQR scaler;
- categorical vocabulary;
- feature ordering;
- sequence length与packet-selection policy;
- context relation;
- context window;
- classification threshold。

外部数据标签只能用于:

- confusion matrix;
- F1、precision、recall;
- ROC-AUC;
- AP;
- 最终统计分析。

必须说明的事项

论文需要回答:

1. 外部数据是否使用源训练集的 scaler?
2. CICIDS 中未见过的类别如何处理?
3. Stage 1 和 Stage 2 是否都未在 CICIDS 上训练?
4. 阈值是否来自源域 validation set?
5. 每个窗口的 context 是否从空历史开始?
6. w01 到 w08 之间是否传递 Stage 2 历史状态?
7. 为什么没有报告 w03、w04、w05?
8. 窗口是否在查看结果之前预先确定?
9. 两个数据集的标签语义是否完全一致?
10. CICIDS 原始标签如何映射到二分类标签?

特别是第 7 点：目前只出现 w01、w02、w06、w07、w08。如果 w03–w05 是因为缺少正类、数据无效或未满足构造条件，应明确说明。若它们是因为表现较差而未报告，就会产生 selection bias。

十一、论文中建议新增的结果表

可以增加如下主表：

```
\begin{table}[H]
\centering
\caption{External evaluation across the public CICIDS2017 Wednesday
windows and a separate company server capture.}
\begin{tabular}{lrrrrrr}
\toprule
Dataset/window & $N$ & Positive (\%) & Macro-F1 &
$F_{1,1}$ & ROC-AUC & AP \\
\midrule
CICIDS w01 & 20,000 & 18.20 & 0.9125 & 0.8569 & 0.9816 & 0.9088 \\
CICIDS w02 & 20,000 & 13.52 & 0.9226 & 0.8663 & 0.9728 & 0.9123 \\
CICIDS w06 & 20,000 & 16.48 & 0.8536 & 0.7479 & 0.9758 & 0.8906 \\
CICIDS w07 & 20,000 & 13.34 & 0.8640 & 0.7651 & 0.9691 & 0.8419 \\
CICIDS w08 & 20,000 & 15.24 & 0.9220 & 0.8688 & 0.9884 & 0.9397 \\
Company cross-server & 38,513 & 3.28 & 0.9026 &
0.8112 & 0.9870 & 0.8771 \\
\bottomrule
\end{tabular}
\end{table}
```

再增加一个 error table：

```
\begin{table}[H]
\centering
\caption{Operating-point errors in the external evaluation.}
\begin{tabular}{lrrrrrr}
\toprule
Dataset/window & TN & FP & FN & TP & FPR (\%) \\
\midrule
CICIDS w01 & 15,830 & 531 & 513 & 3,126 & 3.2468 \\
CICIDS w02 & 16,914 & 383 & 345 & 2,358 & 2.2143 \\
CICIDS w06 & 16,521 & 183 & 1,218 & 2,078 & 1.0955 \\
CICIDS w07 & 16,622 & 710 & 575 & 2,093 & 4.0965 \\
CICIDS w08 & 16,405 & 548 & 286 & 2,761 & 3.2325 \\
CICIDS pooled & 82,292 & 2,355 & 2,937 & 12,416 & 2.7821 \\
Company cross-server & 37,087 & 161 & 292 & 973 & 0.4322 \\
\bottomrule
\end{tabular}
\end{table}
```

十二、可用于论文的英文结果分析

可以使用下面这段作为基础：

> External evaluation was conducted without treating CICIDS2017 as organisational data. The source models were developed on `ar002\_et12\_20260511\_001`, while five non-overlapping chronological windows from the publicly available CICIDS2017 Wednesday-workingHours capture were used for cross-dataset evaluation. Each window contained 20,000 flows. Across the resulting 100,000 external flows, the pooled confusion matrix contained 82,292 true negatives, 2,355 false positives, 2,937 false negatives, and 12,416 true positives. This corresponds to a pooled macro-F1 of 0.8966, class-1 F1 of 0.8243, and FPR of 2.7821%.

> Performance varied across time. Window-level macro-F1 ranged from 0.8536 to 0.9226. In window w06, class-1 precision remained high at 0.9191, but recall fell to 0.6305, indicating a conservative operating point with 1,218 missed positive flows. Window w07 instead produced the largest number of false positives and the lowest average precision, suggesting weaker separation rather than only a threshold shift. By contrast, w08 achieved the strongest class-1 F1 and average precision. The variation demonstrates that external performance should be characterised across chronological segments rather than through a single favourable aggregate.

> A second external evaluation used 38,513 flows captured from a different company server. The model achieved a macro-F1 of 0.9026, class-1 F1 of 0.8112, ROC-AUC of 0.9870, and average precision of 0.8771. Its FPR remained low at 0.4322%, although class-1 recall declined to 0.7692. The cross-server degradation was therefore expressed primarily through missed positive flows rather than an increase in false alerts.

十三、最终结论

这些外部测试明显增强了论文，因为它们补上了原稿最重要的限制之一：只在单一捕获上进行内部评估。

目前结果支持以下结论：

- 模型在公共 CICIDS2017 数据上保持了接近 0.90 的总体 Macro-F1；
- 外部泛化并非偶然集中在单一窗口；
- 但不同时间窗口之间存在显著性能变化；
- w06 暴露了漏报风险；
- w07 暴露了误报和排序退化；
- 公司跨服务器测试保持了低 FPR 和较强 AP；
- 跨服务器主要退化是正类召回下降；
- source-host 上下文具有一定跨环境可迁移性，但并非始终稳定；
- 论文可以从“尚未验证外部泛化”升级为“已经提供初步跨数据集和跨服务器验证”。

最稳妥的总结是：

> The external results provide evidence of meaningful, but non-uniform, generalisation across a public benchmark and a separate organisational server environment. Performance remained strong overall, while the variation in false-positive and false-negative behaviour across chronological windows indicates sensitivity to temporal and domain shift.

不要写成“证明模型具有普遍泛化能力”；当前证据更适合称为：

> preliminary external-generalisation evidence.

用户 2026-08-05 13:13:35

在我的latex的基础上，和我上面的外部测试，我该将这个放到那个模块？新增那些模块？修改那些地方？
请提供具体该修改哪里？还有修改后的latex（不修改的地方尽量保持不变）

助手 2026-08-05 13:13:54

我会在原稿上做“最小侵入式”修改：保留现有章节结构和内部实验结果，只新增外部数据说明、外部评估协议、外部结果与讨论，并同步修改摘要、贡献、结论和局限性中已经过时的“尚未进行外部验证”表述。我会生成一个新的`.tex`文件，不覆盖你 Downloads 中的原稿。

助手 2026-08-05 13:15:22

结构上，外部测试最适合放在三处形成闭环：Dataset 章节说明“测什么”，Experimental Methodology 说明“怎样保证是外部测试”，Results 章节报告“得到什么”。摘要、Introduction 和 Conclusion 只同步提炼结论，不另行重复方法细节。现在我正在加入两张外部结果表和窗口差异分析。

助手 2026-08-05 13:18:18

我已经基于原稿生成了修改版 LaTeX，没有覆盖原文件：

[main_external_revision.tex](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex)

修改遵循“原文尽量不动”的原则，只新增外部验证所需内容，并同步修改已经失效的结论。

推荐放置结构

外部测试不应只放在 Results 中，而应该形成完整链条：

章节	新增/修改内容	作用
Abstract	增加两类外部测试及核心结果	摘要呈现完整贡献
Introduction	增加 external evaluation contribution	对应论文贡献
Dataset Construction	新增 External Evaluation Datasets	解释测试数据是什么
Experimental Methodology	新增 External Evaluation Protocol	解释怎样测试、如何防止泄漏
Results and Discussion	新增 External Generalisation	报告结果并分析窗口差异
Cross-Stage Discussion	加入外部迁移解释	连接内部和外部证据
Conclusion	加入外部验证结论	更新研究结论
Limitations	删除“没有外部测试”	改为“外部覆盖仍有限”
Future Work	从“首次外部验证”改成“扩大外部验证”	与已完成实验保持一致

一、Abstract 修改

位置：

[main_external_revision.tex:55](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:55)

主要修改：

- 将不够严格的 `causal history` 改为 `start-time-ordered history`；
- 将 `PR-AUC` 的主要称呼改为更准确的 `average precision`；
- 修正 Stage 1 controlled manifest 的 Macro-F1 为 0.8955；
- 增加 CICIDS2017 五窗口；
- 增加公司不同服务器测试；
- 删除“external generalisation 尚未建立”的过时表述。

新增摘要核心内容为：

External evaluation uses five non-overlapping 20,000-flow windows from the public CICIDS2017 Wednesday capture and a 38,513-flow company capture obtained from a different server. Pooled macro-F1 across the five public windows is 0.8966, while the separate-server capture reaches 0.9026.

这样摘要同时保留：

- 内部 Stage 1 结果;
- 内部 Stage 2 结果;
- 公共跨数据集结果;
- 公司跨服务器结果。

二、Introduction 的贡献列表

位置:

[main_external_revision.tex:95](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:95)

新增第四项贡献:

```
\item External evaluation on chronological windows from the public
CICIDS2017 Wednesday capture and on a separate company-provided
server capture, complementing the source-domain chronological test.
```

这项贡献的措辞比较克制:

- 没有把 CICIDS2017 写成公司数据;
- 没有声称普遍泛化;
- 明确外部测试是对内部时间测试的补充。

三、Dataset 章节新增模块

新增位置:

[main_external_revision.tex:237](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:237)

新增模块:

```
\section{External Evaluation Datasets}
\label{subsec:external_datasets}
```

该模块明确区分三个数据集:

源数据

```
\datasetfield{ar002_et12_20260511_001}
```

用于模型训练、验证和源域内部测试。

公共外部数据

```
CICIDS2017 Wednesday-workingHours
```

被准确描述为:

```
the publicly available CICIDS2017 Wednesday-workingHours capture
```

并引用现有 BibTeX 条目:

```
\cite{Sharafaldin2018CICIDS}
```

因此不需要为 CICIDS2017 新增 BibTeX 条目。

公司跨服务器数据

```
\datasetfield{firewall_test_20250731_160700}
```

被描述为：

```
a cross-server organisational test
```

没有将它夸大为跨组织测试。

新增的数据限制说明

这一节还明确指出：

- CICIDS 五窗口正类比例为 13.34%–18.20%;
- firewall 数据正类比例为 3.285%;
- 数据采集、流量组成、标签来源和类别比例可能不同;
- 外部结果不能证明模型对任意网络具有不变性能。

四、修改原 Dataset limitation

原论文写的是：

```
\textbf{Single-trace scope.}
Evidence from one company capture cannot establish generalisation...
Evaluation on external PCAPs remains necessary.
```

这已经与现在的实验不一致。

修改位置：

[main_external_revision.tex:646](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:646)

现在改为：

```
\item \textbf{Limited multi-source scope.}
Model development and ablation evidence comes from one company
source capture. The public CICIDS2017 windows and separate-server
company capture extend evaluation beyond that source, but two
external sources cannot establish generalisation across arbitrary
organisations, sensors, rulesets, or extended periods.
```

这个版本准确表达：

- 主要开发和消融仍然只有一个源数据;
- 已经进行了外部测试;
- 但外部覆盖仍然有限。

五、Experimental Methodology 新增模块

新增位置：

[main_external_revision.tex:1220](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1220)

新增：

```
\subsection{External Evaluation Protocol}
\label{subsec:external_evaluation_protocol}
```

这一节说明：

- `ar002\_et12\_20260511\_001` 是唯一源训练数据;
- CICIDS 和 firewall 不进入源数据训练划分;
- 使用源数据训练的 Stage 1 和 Stage 2 checkpoint;
- 外部标签只用于计算最终指标;
- scaler、clipping limits、category vocabulary、checkpoint、context relation、window size 和 threshold 全部固定;
- 外部标签不能用于 early stopping、threshold selection 或 model selection;
- CICIDS 按时间顺序形成不重叠的 20,000-flow 窗口;
- pooled AP/ROC-AUC 不能通过 confusion matrix 推导。

加入这部分非常重要，因为答辩老师看到外部结果后，通常首先会问：

> 外部数据有没有参与预处理、调阈值或重新训练？

当前修改版已经给出了严格 frozen external test 的标准表述。

但这段必须以你的真实实验流程为准。如果外部运行重新训练了 Stage 2，或使用外部标签选择阈值，这几句必须进一步调整，不能保留为严格冻结测试。

六、Results 新增 External Generalisation

新增位置：

[main_external_revision.tex:1655](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1655)

新增完整章节：

```
\section{External Generalisation}
\label{subsec:results_external_generalisation}
```

放置位置是在：

```
\subsection{Efficiency and Operational Trade-Offs}
```

之后，以及：

```
\section{Cross-Stage Discussion}
```

之前。

这是最合适的位置，因为外部测试属于完整系统结果，而不是单独的 Stage 1 ablation 或 Stage 2 architecture comparison。

七、新增外部预测指标表

位置：

[main_external_revision.tex:1660](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1660)

表格包含：

- 样本量;
- 正类比例;
- Accuracy;
- Macro-F1;

- Class-1 F1;
- ROC-AUC;
- AP。

其中结果保持为你提供的原始结果，只进行四位小数格式化：

```
\begin{table}[H]
  \centering
  \caption{External evaluation on public CICIDS2017 Wednesday
windows and a separate company server capture. The reported
PR-AUC field is average precision.}
  \label{tab:results_external_scores}
  \resizebox{\textwidth}{!}{%
    \begin{tabular}{@{}lrrrrrrr@{}}
      \toprule
      Dataset/window & Flows & Positive (\%) & Accuracy &
      $F_{1,\mathrm{macro}}$ & $F_{1,1}$ & ROC-AUC & AP \\
      \midrule
      CICIDS2017 w01 & 20,000 & 18.195 & 0.9478 &
      0.9125 & 0.8569 & 0.9816 & 0.9088 \\
      CICIDS2017 w02 & 20,000 & 13.515 & 0.9636 &
      0.9226 & 0.8663 & 0.9728 & 0.9123 \\
      CICIDS2017 w06 & 20,000 & 16.480 & 0.9300 &
      0.8536 & 0.7479 & 0.9758 & 0.8906 \\
      CICIDS2017 w07 & 20,000 & 13.340 & 0.9358 &
      0.8640 & 0.7651 & 0.9691 & 0.8419 \\
      CICIDS2017 w08 & 20,000 & 15.235 & 0.9583 &
      0.9220 & 0.8688 & 0.9884 & 0.9397 \\
      Company cross-server & 38,513 & 3.285 & 0.9882 &
      0.9026 & 0.8112 & 0.9870 & 0.8771 \\
      \bottomrule
    \end{tabular}%
  }
\end{table}
```

八、新增 confusion matrix 表

位置：

[main_external_revision.tex:1683](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1683)

新增表格包括：

- TN;
- FP;
- FN;
- TP;
- FPR。

还增加了五个 CICIDS 窗口的 pooled confusion matrix:

```
\[
\begin{bmatrix}
82292 & 2355 \\
2937 & 12416
\end{bmatrix}
```

对应:

- pooled Macro-F1: 0.8966;
- pooled Class-1 F1: 0.8243;
- pooled FPR: 2.7821%。

LaTeX 内容为:

```
\begin{table}[H]
\centering
\caption{External-test confusion matrices and
operating-point error rates.}
\label{tab:results_external_errors}
\begin{tabular}{@{}lrrrrr@{}}
\toprule
Dataset/window & TN & FP & FN & TP & FPR (\%) \\
\midrule
CICIDS2017 w01 & 15,830 & 531 & 513 & 3,126 & 3.2468 \\
CICIDS2017 w02 & 16,914 & 383 & 345 & 2,358 & 2.2143 \\
CICIDS2017 w06 & 16,521 & 183 & 1,218 & 2,078 & 1.0955 \\
CICIDS2017 w07 & 16,622 & 710 & 575 & 2,093 & 4.0965 \\
CICIDS2017 w08 & 16,405 & 548 & 286 & 2,761 & 3.2325 \\
\midrule
CICIDS2017 pooled & 82,292 & 2,355 & 2,937 & 12,416 & 2.7821 \\
Company cross-server & 37,087 & 161 & 292 & 973 & 0.4322 \\
\bottomrule
\end{tabular}
\end{table}
```

九、新增结果讨论

外部结果讨论位于:

[main_external_revision.tex:1701](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1701)

内容重点不是简单重复指标，而是解释不同失败模式:

- w01、w02: precision/recall 比较平衡;
- w08: Class-1 F1 和 AP 最好;
- w06: 高 precision、低 recall，主要是漏报;
- w07: FP 最高且 AP 最低，不只是阈值问题;
- firewall: FPR 很低，但 recall 下降;
- 外部迁移有价值，但不是均匀的。

对于 w06，修改版使用了比较谨慎的措辞:

```
this pattern is compatible with probability or threshold
miscalibration under temporal shift rather than complete loss
of ranking ability
```

这里使用 `compatible with`，没有断言一定是 calibration 问题，因为还没有概率分布和攻击类型数据证明具体原因。

十、Cross-Stage Discussion 修改

位置:

[main_external_revision.tex:1716](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1716)

新增外部结果与两阶段方法的联系：

External evaluation further shows that useful signal persists across a public benchmark and a different company server, although its strength and error balance vary by environment and chronological window.

这使外部结果不再像一个孤立附录，而是回到论文的主要研究论证中。

十一、Conclusion 修改

位置：

[main_external_revision.tex:1732](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1732)

新增结论：

The external tests additionally show that useful discrimination persists on chronological windows from the public CICIDS2017 Wednesday capture and on a separate company server, reaching pooled macro-F1 of 0.8966 and cross-server macro-F1 of 0.9026, respectively. The variation between external windows nevertheless shows that transfer is non-uniform.

同时修复了原文中的排版错误：

capture.The

改为：

capture. The

十二、Limitations 修改

位置：

[main_external_revision.tex:1748](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1748)

原来的：

Transfer across networks, time periods, and rulesets has not been evaluated.

已经删除，因为现在不再属实。

替换为：

External transfer has been evaluated on public CICIDS2017 Wednesday windows and on a different company server, but this coverage remains limited to two external sources.

并继续限定：

- 无法证明对任意组织泛化；
- 标签来源不同；
- 攻击组成不同；
- class prevalence 不同；

- 仍然只有一个训练 seed。

十三、Future Work 修改

位置：

[main_external_revision.tex:1774](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1774)

未来工作不再写“需要进行外部验证”，而改为：

The present CICIDS2017 and cross-server tests should be extended to additional days, public datasets, organisations, and repeated captures.

也就是从：

> 尚未进行外部测试

升级为：

> 已经有初步外部证据，但需要扩大数据覆盖。

十四、需要你确认的三个事实

修改版的 external protocol 按“严格冻结外部测试”撰写。提交前必须确认以下事实确实成立：

1. CICIDS 和 firewall 测试没有重新训练 Stage 1 或 Stage 2;
2. scaler、category vocabulary 和其他预处理参数全部来自 `ar002` 训练集;
3. 分类阈值来自 `ar002` validation set, 而不是外部标签。

如果任意一点不成立，应该将术语改为：

- supervised transfer;
- external-domain adaptation;
- target-domain calibration;

而不能称为完全冻结的 external test。

另外，需要在论文中解释为什么报告：

w01, w02, w06, w07, w08

但没有 w03、w04、w05。可能原因包括：

- 这些窗口没有形成有效测试 pair;
- 不满足最小正类数量;
- 数据完整性检查失败;
- 不是预先选定的窗口。

必须写明真实原因，否则审阅者可能怀疑只选择了有利窗口。

十五、校验结果

修改文件已经完成静态检查：

- 新增引用键均能在 `sources.bib` 中找到;
- 没有新增缺失的 `\label`;
- 没有新增重复 label;
- 左右花括号数量一致;
- CICIDS2017 使用现有 `Sharafaldin2018CICIDS` 引用;
- 原论文其他方法和结果内容保持不变。

当前环境没有检测到 `pdflatex`/`bibtex`，并且完整编译还依赖：

- `mcs.sty`;
- `MScCS/overallFramework.png`;
- `MScCS/ArchitecturalOverview.png`;
- `figures/` 中的结果 PDF;
- `sources.bib`。

因此我完成了 LaTeX 静态结构校验，但没有在此环境生成最终 PDF。

用户 2026-08-05 13:45:59

我的论文中使用了PR-AUC (computed as Average Precision)。只需要在论文中第一次出现时给出定义即可。后续都用这个名字，所以上面的最新的latex不要修改这个。

我为什么选择了w01, w02, w06, w07,

w08这几个窗口？是因为他和我的真实数据中的label1的分布都是1占比较少，0占大多数。

结合我的要求和在我的latex的基础上，和我上面的外部测试，我该将这个放到那个模块？新增那些模块？修改那些地方？

请提供具体该修改哪里？还有修改后的latex（不修改的地方尽量保持不变）

助手 2026-08-05 13:46:14

明白。我会保留你论文统一使用的名称 `PR-AUC`，只在全文第一次出现时写成 `PR-AUC (computed as average precision)`，后续表格和讨论全部继续写 `PR-AUC`。同时会明确说明五个窗口是按类别分布条件选择的——label 1 为少数、label 0 为多数——而不是按模型成绩挑选；并把这种窗口筛选对外部结论范围的限制写清楚。

助手 2026-08-05 13:47:49

已按你的命名规则完成调整：全文现在只在摘要第一次出现时定义 `PR-AUC (computed as average precision)`，后续统一使用 `PR-AUC`，包括公式、表头和外部结果讨论。五个 CICIDS2017 窗口的选择依据也已写入 Dataset、实验协议和结果解释，并明确这是类别分布筛选而不是按模型分数筛选。

助手 2026-08-05 13:48:59

已根据你的两个要求重新修改：

1. 第一次出现写作 `PR-AUC (computed as average precision)`，后续全部统一使用 `PR-AUC`；
2. 明确说明选择 w01、w02、w06、w07、w08，是因为这些窗口保持 label 1 为少数类、label 0 为多数类，与源数据的类别不平衡方向一致，而不是根据模型表现选择。

修改后的完整文件：

```
[main_external_revision.tex](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex)
```

原始 Downloads 文件没有被覆盖。

一、外部测试应该放在哪些模块

建议保留当前修改版的三层结构。

1. Dataset Construction and Preprocessing

新增：

```
\section{External Evaluation Datasets}
```

位置：

[main_external_revision.tex:237](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:237)

作用：

- 说明 CICIDS2017 是公共数据；
- 说明 firewall 数据是公司不同服务器数据；
- 说明窗口如何构造；
- 说明为什么选择这五个窗口；
- 说明这种筛选对结论范围的影响。

2. Experimental Methodology

新增：

```
\subsection{External Evaluation Protocol}
```

位置：

[main_external_revision.tex:1220](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1220)

作用：

- 说明源数据与外部数据的角色；
- 说明模型是否冻结；
- 说明窗口筛选规则；
- 说明不存在根据模型成绩选择窗口；
- 说明 pooled PR-AUC 不能通过 confusion matrix 推导。

3. Results and Discussion

新增：

```
\section{External Generalisation}
```

位置：

[main_external_revision.tex:1655](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1655)

作用：

- 报告五个 CICIDS2017 窗口；
- 报告公司跨服务器结果；
- 提供 pooled confusion matrix；
- 分析不同窗口的误报、漏报和 PR-AUC 差异；

- 给出适当限定的外部泛化结论。

二、PR-AUC 命名修改

第一次出现

全文第一次出现位于摘要：

[main_external_revision.tex:57](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:57)

现在写作：

PR-AUC (computed as average precision)

完整句子为：

Because positive flows are scarce, the analysis gives priority to macro-F1, PR-AUC (computed as average precision), attack-class performance, confusion matrices, and false-positive rate.

后续使用

后续全部统一写成：

PR-AUC

包括：

- 摘要结果；
- 实验配置；
- 模型选择；
- 评价指标；
- 所有内部结果；
- 外部结果表；
- w06、w07、w08 讨论；
- 公司跨服务器结果。

外部结果表的表头现在是：

$F_{1,\mathrm{macro}}$ & $F_{1,1}$ & ROC-AUC & PR-AUC

没有再使用 `AP` 作为指标名称。

指标公式部分

原稿评价指标章节仍然保留实现细节，但名称统一为 PR-AUC：

The reported `\texttt{pr\_auc}` field is produced by scikit-learn's `\texttt{average\_precision\_score}`, rather than by trapezoidal integration under linearly interpolated precision--recall points:

公式改为：

```
\begin{equation}
\mathrm{PR\mbox{-}AUC}
= \sum_k (R_k - R_{k-1}) P_k,
\label{eq:average_precision}
\end{equation}
```

后续说明为：

```
The name PR-AUC is used consistently throughout the thesis
for this implementation.
```

因此满足你的要求：定义实现方式，但全文指标名称保持一致。

三、窗口选择原因放在哪里

窗口选择原因现在放在两个主要位置。

Dataset 章节

新增表述：

```
To preserve the qualitative class-imbalance condition of the
source task, external windows are retained when label~1 remains
the minority class and label~0 the majority class. Under this
prevalence-based criterion, the evaluated windows are
\texttt{w01}, \texttt{w02}, \texttt{w06}, \texttt{w07}, and
\texttt{w08}, contributing 100,000 flows in total. The criterion
concerns class composition rather than model performance.
```

这段说明了：

- 筛选依据是类别比例；
- label 1 必须少于 label 0；
- 目标是保持与源任务相同的不平衡方向；
- 不是因为这些窗口的模型结果更好。

Experimental Methodology

进一步写明：

```
Before model-performance comparison, windows are screened by
class composition: label~1 must remain less frequent than
label~0, matching the qualitative imbalance direction of the
source dataset. This prevalence criterion yields
\texttt{w01}, \texttt{w02}, \texttt{w06}, \texttt{w07}, and
\texttt{w08}; it is not defined from their predictive scores.
```

这段特别重要，因为它把窗口选择变成了正式的 experimental inclusion criterion。

四、为什么还要说明选择带来的限制

虽然你的选择理由是合理的，但这些窗口并不代表完整 Wednesday-workingHours 数据。因此，修改版同时加入：

```
Selecting CICIDS2017 windows in which label~1 remains the
minority improves comparability with the imbalanced source task,
but it also limits the external claim to windows satisfying that
condition rather than the complete Wednesday capture.
```

这句话可以防止答辩时被质疑：

> 为什么没有测试全部窗口？

你的回答可以是：

> 论文研究的是不平衡 NIDS，源数据中 label 1

是少数类。为了避免把类别结构完全不同的窗口与源任务直接比较，我预先采用类别分布条件，只保留 label 1

少于 label 0 的非重叠时间窗口。该条件与模型分数无关。同时，我将结论限定为满足这一类别条件的 CICIDS2017 窗口，而不是完整 Wednesday capture。

这是比单纯说“因为正类比较少”更规范的学术表述。

五、Dataset 新增内容

位置：

[main_external_revision.tex:237](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:237)

主要内容如下：

```
\section{External Evaluation Datasets}
\label{subsec:external_datasets}

Two datasets that are disjoint from the source capture are used
to examine transfer beyond its internal chronological test. The
first is the publicly available CICIDS2017
Wednesday-workingHours capture, corresponding to Wednesday,
5 July 2017 \cite{Sharafaldin2018CICIDS}. CICIDS2017 is not
company-provided traffic and is treated as a public
cross-dataset test. Compatible Stage~1 external-test artefacts
are ordered chronologically and divided into multiple
non-overlapping windows of 20,000 flows. To preserve the
qualitative class-imbalance condition of the source task,
external windows are retained when label~1 remains the minority
class and label~0 the majority class. Under this
prevalence-based criterion, the evaluated windows are
\texttt{w01}, \texttt{w02}, \texttt{w06}, \texttt{w07}, and
\texttt{w08}, contributing 100,000 flows in total. The
criterion concerns class composition rather than model
performance. Window-level reporting is retained because
aggregate performance alone can conceal temporal variation in
false-positive and false-negative behaviour.
```

公司数据继续单独描述：

```
The second external dataset,
\datasetfield{firewall_test_20250731_160700}, was supplied by
the company but collected from a server environment different
from that of
\datasetfield{ar002_et12_20260511_001}. It contains 38,513
evaluated flows and is used as a cross-server organisational
test.
```

六、实验协议新增内容

位置：

[main_external_revision.tex:1220](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1220)

核心 LaTeX 为：

```
\subsection{External Evaluation Protocol}
\label{subsec:external_evaluation_protocol}

External evaluation keeps
\datasetfield{ar002_et12_20260511_001} as the source training
dataset and does not merge either external dataset into the
source chronological partitions. The source-trained Stage~1
```

and Stage~2 checkpoints are applied to compatible external-test artefacts. External labels are reserved for metric calculation. Feature order, training-fitted clipping and scaling parameters, categorical vocabularies, model checkpoints, context relation, context capacity, and the source-validation decision threshold remain unchanged. No external test label is used for checkpoint selection, early stopping, threshold selection, or model comparison.

窗口筛选:

For CICIDS2017, the external flows are kept in chronological order and divided into non-overlapping 20,000-flow windows. Before model-performance comparison, windows are screened by class composition: label~1 must remain less frequent than label~0, matching the qualitative imbalance direction of the source dataset. This prevalence criterion yields $\texttt{w01}$, $\texttt{w02}$, $\texttt{w06}$, $\texttt{w07}$, and $\texttt{w08}$; it is not defined from their predictive scores.

七、外部结果模块

位置:

[main_external_revision.tex:1655](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1655)

结果表现在统一使用 PR-AUC:

```
\begin{table}[H]
\centering
\caption{External evaluation on prevalence-compatible public
CICIDS2017 Wednesday windows and a separate company server
capture.}
\label{tab:results_external_scores}
\resizebox{\textwidth}{!}{%
\begin{tabular}{@{}lrrrrrrr@{}}
\toprule
Dataset/window & Flows & Positive (\%) & Accuracy &
 $F_{1, \text{macro}}$  &  $F_{1,1}$  &
ROC-AUC & PR-AUC \\
\midrule
CICIDS2017 w01 & 20,000 & 18.195 & 0.9478 &
0.9125 & 0.8569 & 0.9816 & 0.9088 \\
CICIDS2017 w02 & 20,000 & 13.515 & 0.9636 &
0.9226 & 0.8663 & 0.9728 & 0.9123 \\
CICIDS2017 w06 & 20,000 & 16.480 & 0.9300 &
0.8536 & 0.7479 & 0.9758 & 0.8906 \\
CICIDS2017 w07 & 20,000 & 13.340 & 0.9358 &
0.8640 & 0.7651 & 0.9691 & 0.8419 \\
CICIDS2017 w08 & 20,000 & 15.235 & 0.9583 &
0.9220 & 0.8688 & 0.9884 & 0.9397 \\
Company cross-server & 38,513 & 3.285 & 0.9882 &
0.9026 & 0.8112 & 0.9870 & 0.8771 \\
\bottomrule
\end{tabular}%
}
\end{table}
```

结果讨论也已经全部使用 PR-AUC:

while w08 gives the strongest class-1 F1 and PR-AUC

Since ROC-AUC and PR-AUC remain 0.9758 and 0.8906

It has the largest FP count and the lowest PR-AUC

PR-AUC reaches 0.8771

八、摘要、贡献、结论和限制同步修改

除了三个新增模块，以下位置也已经同步更新：

- Abstract: [第 55–57

行附近](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:55)

- Introduction contributions: [第 95

行附近](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:95)

- Dataset limitations: [第 646

行附近](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:646)

- Cross-stage discussion: [第 1716

行附近](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1716)

- Conclusion: [第 1732

行附近](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1732)

- Limitations: [第 1748

行附近](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1748)

- Future work: [第 1774

行附近](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex:1774)

九、最终校验

修改版已通过静态检查：

- 缺失 citation key: 0;
- 缺失 label: 0;
- 重复有效 label: 0;
- 左右花括号数量一致;
- `average precision` 文字只在第一次定义中出现;
- 外部结果后续全部统一使用 `PR-AUC`;
- 原始 `main.tex` 未被覆盖。

最终文件：

[main_external_revision.tex](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex)
)

用户 2026-08-05 16:28:04

我需要修改部分的中文版本，这样我可以检查

助手 2026-08-05 16:28:14

我会把所有新增或改写的段落逐段翻译成中文，并按原 LaTeX 中的章节位置排列，方便你逐项核对含义。公式、指标数值和表格结构保持不变；中文仅用于审阅，不替换英文论文正文。

助手 2026-08-05 16:29:45

已生成全部修改部分的中文审阅版：

[external_revision_chinese_review.md](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/external_revision_chinese_review.md)

内容按英文论文位置逐项对应，包括：

- 摘要修改；
- Introduction 新增贡献；
- External Evaluation Datasets；
- External Evaluation Protocol；
- 两张外部结果表；
- CICIDS2017 各窗口讨论；
- 公司跨服务器结果；
- Cross-Stage Discussion；
- Conclusion；
- Limitations；
- Future Work。

英文修改版仍在：

[main_external_revision.tex](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex)

请重点检查中文审阅版最后的六项实验事实，特别是：

- Stage 2 是否没有在外数据上重新训练；
- 外部测试是否继续使用源验证集阈值；
- 五个窗口是否确实在查看模型成绩前，按 “label 1 少于 label 0” 筛选。

这些事实决定论文能否将实验准确称为严格冻结的外部测试。

用户 2026-08-05 16:32:57

我现在的论文中需要appendix，我可以加入那些appendix？详细解析

助手 2026-08-05 16:34:40

你的论文非常适合加入 Appendix。当前正文已经比较完整，但数据处理、模型配置和外部测试细节较多；如果全部留在正文，会打断主线，而完全不提供又会削弱可复现性。

Appendix 最应该解决三个问题：

- 实验能否被审查和复现；
- 外部测试是否严格、是否存在窗口选择偏差；
- 正文图表没有展示的完整结果是否可查。

一、推荐的 Appendix 结构

建议设置 6 个附录：

Appendix 建议名称 重要性
--- --- ---
A Complete Feature and Metadata Specification 必须
B Model and Training Configurations 必须
C External Evaluation Protocol and Window Construction 必须
D Complete Experimental Results 必须

| E | Data Integrity, Leakage, and Reproducibility Checks | 强烈建议 |
| F | Ethical, Privacy, and Artefact-Availability Statement | 建议 |

如果篇幅有限，至少保留 A–D。

Appendix A: 完整特征与元数据说明

建议标题：

```
\chapter{Complete Feature and Metadata Specification}  
\label{app:feature_specification}
```

应包含什么

A.1 Stage 1 packet predictors

正文已经列出 23 个原始 packet predictors，但附录可以进一步提供：

- 字段名称；
- 数据类型；
- 单位；
- 缺失值处理；
- 是否执行 `log1p`；
- 是否 clipping；
- 是否 scaling；
- 最终编码方式。

建议表格：

Feature	Type	Unit	Transformation	Missing handling
--- --- --- --- ---				
`pkt_len`	Numerical	bytes	log1p, clipping, robust scaling	zero after log transform
`protocol`	Categorical	—	one-hot	`MISSING`
`tcp_syn`	Binary	—	binarisation	zero
`direction`	Binary	—	binarisation	zero

目前正文只说“哪些变量被使用”，附录可以说明“每个变量具体怎样处理”。

A.2 Flow-statistics predictors

这是当前论文比较需要补充的部分。

正文写道 Scheme C 使用一个“configured subset”，但没有完整列出这个 subset。审阅者可能会问：

> Scheme C 的 flow branch 到底包含哪些变量？

附录应完整列出：

- flow duration；
- directional packet counts；
- byte totals；
- packet-length statistics；
- flow IAT；
- directional IAT；
- flag counts；

- header lengths;
- rates;
- active/idle statistics;
- initial TCP windows;
- availability indicators.

不要只写 “selected flow statistics” ， 应给出确切列表。

A.3 Stage 2 metadata

明确区分：

Field	Predictor?	Context construction?	Target?
`flow_id`	No	Alignment only	No
`flow_start_timestamp_us`	No	Chronological ordering	No
`source_ip`	No	Source-host equality	No
`destination_ip`	No	Destination/endpoint equality	No
`label`	No	No	Yes
Stage 1 embedding	Yes	Context content	No

这张表能非常清楚地证明：

- IP 地址没有被直接作为预测特征；
- label 没有进入上下文；
- metadata 只用于关系构造。

A.4 Excluded variables

列出所有主动排除的字段及原因：

- IP addresses：避免身份记忆；
- ports：避免服务或环境捷径；
- absolute timestamps：避免捕获位置泄漏；
- labels：直接目标泄漏；
- alert fields：Suricata 信息泄漏；
- flow/packet ID：唯一标识符；
- TCP sequence/ack numbers：可能产生不稳定捷径；
- `l7\_proto`：可能过度依赖 Suricata 协议解析。

这种 “使用/不使用” 对照很适合放在附录。

Appendix B：模型与训练配置

建议标题：

```
\chapter{Model and Training Configurations}
\label{app:model_configurations}
```

B.1 Stage 1 完整配置

正文只给出主要参数，附录应包含完整配置：

- model dimension;
- number of layers;

- attention heads;
- FFN dimension;
- dropout;
- maximum packet length;
- packet selection policy;
- FiLM gate initialisation;
- FiLM maximum norm ratio;
- pooling method;
- classifier hidden dimensions;
- activation function;
- LayerNorm placement;
- padding-mask behaviour.

例如：

```
\begin{table}[H]
\centering
\caption{Complete Stage~1 configuration.}
\begin{tabular}{ll}
\toprule
Setting & Value \\
\midrule
Model dimension & 128 \\
Transformer layers & 2 \\
Attention heads & 4 \\
Feed-forward dimension & 256 \\
Dropout & 0.15 \\
Maximum packet sequence & 128 \\
Packet selection & Head \\
Pooling & Attention + mean + maximum \\
FiLM initial gate &  $\sigma(-5)$  \\
FiLM maximum residual ratio & 0.13 \\
\bottomrule
\end{tabular}
\end{table}
```

B.2 Stage 2 完整配置

包含：

- Stage 1 embedding dimension;
- target-query projection;
- number of attention heads;
- window size;
- maximum historical flows;
- source-host relation;
- age encoding;
- gating network dimensions;
- FFN dimensions;
- classifier dimensions;
- dropout;
- empty-history behaviour.

特别注明：

\[
W=128

\]

包含当前 target, 所以最多只有:

\[

127

\]

个历史 flows。

B.3 Baseline configurations

为每个 baseline 提供完整参数:

- Flow MLP;
- CNN1D;
- CNN1D+time;
- LSTM;
- LSTM+time;
- BiLSTM;
- GRU;
- Vanilla Transformer;
- CNN+LSTM;
- No-context MLP。

这样读者可以判断 baseline 是否被合理实现, 而不是只看到名称。

B.4 Training configuration

详细列出:

- optimiser;
- learning rate;
- weight decay;
- batch size;
- focal γ ;
- focal α ;
- sampling target;
- maximum epochs;
- early stopping;
- scheduler;
- mixed precision;
- random seed;
- validation criterion;
- threshold search range。

建议明确记录:

```
Random seed = 130
```

因为正文表格中该行目前被注释掉了。

Appendix C: 外部评估协议与窗口构造

这是新增外部测试后最重要的附录。

建议标题：

```
\chapter{External Evaluation Protocol and Window Construction}
\label{app:external_protocol}
```

C.1 数据集角色

建议用一张表：

Dataset	Ownership	Training	Validation	Internal test	External test
---	---	---	---	---	---
`ar002_et12_20260511_001`	Company	Yes	Yes	Yes	No
CICIDS2017 Wednesday	Public	No	No	No	Yes
`firewall_test_20250731_160700`	Company, different server	No	No	No	Yes

这能直接消除 CICIDS2017 被误认为公司数据的可能。

C.2 冻结内容

明确列出外部测试中保持不变的部分：

- Stage 1 checkpoint;
- Stage 2 checkpoint;
- selected features;
- feature ordering;
- category vocabulary;
- clipping quantiles;
- median/IQR;
- sequence policy;
- context relation;
- window size;
- classification threshold.

建议写成审计表：

Component	Source	Re-fitted externally?
---	---	---
Numerical scaler	Source training set	No
Category vocabulary	Source training set	No
Stage 1 weights	Source training set	No
Stage 2 weights	Source training set	No
Decision threshold	Source validation set	No
Metrics	External labels	Yes, evaluation only

这张表只应在所有事实确实成立时使用。

C.3 CICIDS 窗口构造算法

提供伪代码：

```
Input: chronologically ordered external flows
Window size: 20,000

1. Sort flows chronologically.
2. Divide them into non-overlapping 20,000-flow windows.
3. Preserve each window's original labels and order.
4. Retain a window if:
```

```
count(label 1) < count(label 0)
5. Do not use model predictions when selecting windows.
6. Evaluate retained windows independently.
```

C.4 为什么是 w01、w02、w06、w07、w08

明确写出：

> 这些窗口不是因为模型分数高而被选择，而是因为它们满足预先指定的类别组成条件：label 1 仍为少数类，label 0 仍为多数类。

附录最好列出所有候选窗口，而不仅是保留窗口：

Window	Label 0	Label 1	Positive rate	Included?	Reason
w01	16,361	3,639	18.195%	Yes	Label 1 minority
w02	17,297	2,703	13.515%	Yes	Label 1 minority
w03	...	...	...	No	填写真实原因
w04	...	...	...	No	填写真实原因
w05	...	...	...	No	填写真实原因
w06	16,704	3,296	16.480%	Yes	Label 1 minority
w07	17,332	2,668	13.340%	Yes	Label 1 minority
w08	16,953	3,047	15.235%	Yes	Label 1 minority

这一表格非常重要。只列入选窗口而不列未入选窗口，仍然可能被质疑选择性报告。

如果 w03–w05 不是因为正类占多数，而是因为：

- 数据不完整；
- 没有有效正类；
- 无法构造 Stage 1 pair；
- 特征不兼容；

就必须填写真实原因，不能统一写成 class imbalance。

C.5 Stage 2 外部上下文边界

需要说明：

- 每个窗口是否独立清空 context；
- w02 是否可以使用 w01 的历史；
- 是否允许使用同一外部窗口内更早的测试 flows；
- 是否允许使用源训练 flows 作为外部 context；
- firewall context 是否完全重新初始化。

这些差异会改变 Stage 2 的结果。

建议加入明确说明：

```
At the beginning of each external window, the Stage~2 context
state was [reset / retained from preceding windows].
```

必须从实际代码确认后选择其中一种。

C.6 标签映射

这是非常关键的一部分：

- CICIDS2017 原始标签怎样转换成二分类？
- `BENIGN` 是否映射为 0？

- 所有攻击类别是否映射为 1?
- firewall 标签是 Suricata 弱标签还是人工标签?
- 外部标签的语义是否与源数据 label 完全一致?

建议提供:

```
| Original label | Binary label |
|---|---|
| BENIGN | 0 |
| DoS slowloris | 1 |
| DoS Slowhttptest | 1 |
| DoS Hulk | 1 |
| DoS GoldenEye | 1 |
| Heartbleed | 1 |
```

只有在真实映射确实如此时才能使用。

Appendix D: 完整实验结果

建议标题:

```
\chapter{Complete Experimental Results}
\label{app:complete_results}
```

正文保留最关键的图表; 附录提供所有详细数字。

D.1 Stage 1 完整结果

每个模型应报告:

- accuracy;
- macro-precision;
- macro-recall;
- macro-F1;
- class-1 precision;
- class-1 recall;
- class-1 F1;
- ROC-AUC;
- PR-AUC;
- TN、FP、FN、TP;
- FPR;
- parameter count;
- training time;
- selected threshold。

D.2 Stage 1 encoding ablation

完整列出:

- position + time;
- position only;
- time only;
- no encoding。

D.3 Fusion results

完整列出：

- Scheme A;
- Scheme B;
- Scheme C。

D.4 Sequence-length results

完整列出：

$\backslash$
 $L \backslash \text{in} \{8, 16, 32, 64, 128, 256\}$
 $\backslash$

以及：

- head;
- head-tail;
- random。

D.5 Stage 2 architecture results

完整列出：

- no-context;
- vanilla Transformer;
- LSTM;
- GRU;
- CNN+LSTM;
- target-query gated attention。

D.6 Context relation results

完整列出：

- time-only;
- source-host;
- destination-host;
- endpoint。

D.7 Context-window results

完整列出：

$\backslash$
 $W \backslash \text{in} \{16, 32, 64, 128, 256\}$
 $\backslash$

D.8 外部测试完整结果

目前正文已有精简外部结果表。附录可以放你原始输出的全部指标，包括：

- weighted precision;
- weighted recall;
- weighted F1;
- loss;

- positive count;
- positive rate;
- threshold;
- confusion matrix。

但正文仍应以 Macro-F1、class-1 F1、PR-AUC 和错误数量为主。

Appendix E: 数据完整性、泄漏和复现检查

建议标题：

```
\chapter{Data Integrity, Leakage, and Reproducibility Checks}
\label{app:integrity_reproducibility}
```

E.1 Packet-flow alignment checks

报告实际数量：

- zero/missing flow IDs removed;
- duplicate flow rows removed;
- unmatched packet flow IDs;
- unmatched flow table IDs;
- final aligned flow count;
- flows with zero packets;
- timestamp-order violations;
- label mismatches。

正文现在描述了检查方法，但没有报告全部实际检查结果。附录适合放具体日志统计。

E.2 Leakage audit

建议表格：

Potential leakage source Control
--- ---
Flow label in predictor Excluded
Packet alert label Excluded
Suricata alert metadata Excluded
Absolute timestamp Context ordering only
IP address Equality relation only
Validation/test preprocessing Training-fitted transformations
Future flows Excluded by start order
Historical labels Never loaded as context
Weighted sampler during export Disabled

E.3 外部测试泄漏检查

加入：

- 外部数据没有进入训练;
- 外部标签没有选择 checkpoint;
- 外部标签没有调 threshold;
- scaler 没有重新 fit;
- 每个 flow 只导出一次;

- context 没有 future flow;
- context 是否在窗口边界清空。

E.4 Artefact lineage

提供类似:

```
Source PCAP
→ packet CSV / flow CSV
→ aligned manifest
→ fitted preprocessing state
→ Stage 1 checkpoint
→ deterministic embeddings
→ Stage 2 contexts
→ Stage 2 checkpoint
→ internal/external predictions
```

每个阶段记录:

- 文件名;
- shape;
- hash;
- creation date;
- configuration file;
- checkpoint identity。

E.5 无法恢复的复现信息

附录不能假装不存在的信息已经存在。应明确列出:

- exact Suricata version unavailable;
- ruleset snapshot unavailable;
- PCAP checksum unavailable;
- exact Python/PyTorch version unavailable;
- exact CPU model unavailable。

这不会使论文更弱; 透明报告比事后猜测更可信。

Appendix F: 隐私、伦理和数据可用性

建议标题:

```
\chapter{Privacy, Ethics, and Artefact Availability}
\label{app:privacy_availability}
```

可包含内容

F.1 公司数据限制

说明:

- 原始 PCAP 不公开;
- IP 地址和端口敏感;
- 论文不报告原始地址;
- 外部共享需要稳定 pseudonymisation;
- pseudonym map 不公开。

F.2 可以共享的内容

例如：

- 模型代码；
- 配置文件；
- 特征列表；
- 数据 schema；
- 预处理代码；
- 训练脚本；
- 不含敏感标识符的聚合结果；
- CICIDS2017 处理说明。

F.3 不可以共享的内容

- 原始公司 PCAP；
- 原始 IP；
- 原始端口映射；
- 内部服务器标识；
- 公司规则配置；
- 未脱敏 CSV。

F.4 CICIDS2017 可用性

CICIDS2017 是公开数据，应提供官方来源和访问日期，但不要将 CICIDS 数据重新描述成论文作者采集的数据。

二、不建议放入 Appendix 的内容

1. 整个源代码

不要把 `custom-out.c`、Stage 1 和 Stage 2 全部代码粘进论文。附录只放：

- 关键伪代码；
- 配置；
- 少量关键逻辑；
- 代码仓库或受限访问说明。

几十页源码通常不会提高论文质量。

2. 原始 IP 地址和端口

绝对不要放：

- source IP；
- destination IP；
- server hostname；
- 真实端口映射；
- 内部网络结构截图。

3. 重复正文的图表

附录应提供正文没有容纳的完整数值，而不是把正文图重新复制一次。

4. 没有解释的训练日志

不建议直接粘贴数百行 Colab 输出。应转换成结构化表格。

三、正文中哪些现有内容可以移入 Appendix

当前正文中的两张完整 raw schema 表较长：

- complete packet CSV schema;
- complete flow CSV schema。

可以保留正文中的简化 feature-family table，然后把完整字段表移到 Appendix A。

正文改成：

```
The extracted packet and flow schemas are summarised here;
their complete field-level specifications are provided in
Appendix~\ref{app:feature_specification}.
```

不过，如果当前论文页数允许，也可以不移动，只在 Appendix 增加“实际使用的 predictor transformation table”。不要同时在正文和附录重复完整 schema。

训练配置同样如此：

- 正文保留 principal configuration;
- 附录放每个 baseline 的全部配置。

四、建议的 LaTeX 骨架

在 Conclusion and Future Work 章节结束后、参考文献之前加入：

```
\appendix

\chapter{Complete Feature and Metadata Specification}
\label{app:feature_specification}

\section{Stage~1 Packet Predictors}
\section{Stage~1 Flow-Statistics Predictors}
\section{Stage~2 Context Metadata}
\section{Excluded Variables and Leakage Rationale}

\chapter{Model and Training Configurations}
\label{app:model_configurations}

\section{Stage~1 Configuration}
\section{Stage~2 Configuration}
\section{Baseline Configurations}
\section{Optimisation and Threshold Selection}

\chapter{External Evaluation Protocol and Window Construction}
\label{app:external_protocol}

\section{Dataset Roles}
\section{Frozen Source-Domain Components}
\section{CICIDS2017 Window Construction}
\section{Window Inclusion Criterion}
\section{External Context Boundaries}
\section{Binary Label Mapping}

\chapter{Complete Experimental Results}
\label{app:complete_results}

\section{Stage~1 Results}
\section{Stage~1 Ablations}
\section{Stage~2 Architecture Results}
\section{Context Relation and Window Results}
\section{External Evaluation Results}

\chapter{Data Integrity, Leakage, and Reproducibility Checks}
```

```

\label{app:integrity_reproducibility}

\section{Packet--Flow Alignment}
\section{Leakage Audit}
\section{External-Test Audit}
\section{Artefact Lineage}
\section{Unavailable Provenance}

\chapter{Privacy, Ethics, and Artefact Availability}
\label{app:privacy_availability}

\section{Organisational Data Protection}
\section{Public and Restricted Artefacts}
\section{Pseudonymisation Requirements}

\bibliographystyle{unsrt}
\bibliography{sources}

```

你的文档类是 `report`，因此在 `appendix` 之后继续使用 `chapter` 是正确的。LaTeX 会自动把章节编号变成：

- Appendix A;
- Appendix B;
- Appendix C.

附录应放在 bibliography 之前。

五、正文中应该怎样引用 Appendix

每个附录至少应在正文被引用一次。

例如 Dataset 章节：

```

A field-level specification of all predictors, transformations,
and context-only metadata is provided in
Appendix~\ref{app:feature_specification}.

```

Experimental Methodology:

```

Complete architecture and baseline configurations are reported
in Appendix~\ref{app:model_configurations}.

```

外部测试协议：

```

The complete window-construction procedure, inclusion criterion,
label mapping, and frozen-component audit are provided in
Appendix~\ref{app:external_protocol}.

```

Results:

```

Complete class-wise metrics, thresholds, confusion matrices,
and efficiency results are reported in
Appendix~\ref{app:complete_results}.

```

Dataset limitations:

```

The complete leakage and reproducibility audit appears in
Appendix~\ref{app:integrity_reproducibility}.

```

六、优先顺序

如果时间有限，按以下顺序完成：

1. Appendix C: 外部评估协议与窗口选择;
2. Appendix D: 完整结果;
3. Appendix B: 模型与训练配置;
4. Appendix A: 完整特征;
5. Appendix E: 泄漏和复现审计;
6. Appendix F: 隐私与可用性。

外部评估 Appendix 最紧急, 因为新增外部结果后, 审阅者最可能追问:

- 为什么只选这五个窗口;
- 是否按结果选择;
- threshold 来自哪里;
- Stage 2 是否重新训练;
- context 是否跨窗口;
- 标签如何映射;
- w03-w05 为什么没有进入测试。

附录应让这些问题都能从论文中直接找到答案。

用户 2026-08-05 16:42:53

Appendix A: 完整特征

结合我的NIDSTransformer下面的代码, 提供完整的特征

助手 2026-08-05 16:43:00

我会以代码中的真实配置和预处理逻辑为准, 核对 Stage 1 packet predictors、flow-statistics predictors、Stage 2 metadata、转换方式和排除字段, 而不是只依据论文文字。先定位实际训练配置、dataset/preprocessing 代码和外部测试配置, 再生成可直接放入论文的 Appendix A LaTeX。

助手 2026-08-05 16:46:29

代码核对后有两个值得在附录中明确的实现细节: 完整 Scheme C 实际配置包含 23 个包级原始预测字段、58 个数值型流统计和 2 个二值流特征; `flow\_iat\_us` 是独立时间输入, 不在这 23 个普通包特征中。另外, 代码中的 `cwe\_flag\_count` 实际统计 TCP CWR flag, 部分所谓 packet-length flow statistics 实际基于 `payload\_len`, 这些都应按真实实现写入附录。

助手 2026-08-05 16:49:56

已根据 NIDSTransformer 的实际代码和主配置生成 Appendix A, 并接入论文:

- [Appendix A 完整 LaTeX](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/appendix_a_complete_features.tex)
- [已接入 Appendix A 的论文](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex)

正文 Feature Selection 部分也新增了对 Appendix A 的引用。

Appendix A 包含的完整内容

1. 23 个包级原始预测字段

- 7 个 numerical;
- 4 个 categorical;
- 12 个 binary。

其中:

- 6 个数值字段执行 log1p;
- `ttl\_or\_hop\_limit` 不执行 log1p;
- 所有数值字段执行训练集分位数裁剪和 robust scaling;
- categorical 使用训练集 one-hot vocabulary;
- binary 使用 `value > 0` 的二值化规则。

2. 独立时间输入

flow_iat_us

它不包含在 23 个普通 packet predictors 中, 而是单独构造 Stage 1 时间张量。

附录还明确说明:

- `log\_flow\_iat\_us` 虽然会被预处理代码派生, 但最终配置将它注释掉;
- `direction\_iat\_us` 没有被选择;
- 模型内部会对存储的 log-IAT 执行 `expm1`, 恢复间隔后计算累积时间坐标。

3. 60 个 flow-branch predictors

包括:

- 58 个数值型 flow statistics;
- 2 个 initial-window availability binary indicators;
- 0 个 categorical flow predictors。

58 个数值字段全部执行:

```
numeric conversion
→ inf to missing
→ log1p
→ zero imputation
→ training q0.001/q0.999 clipping
→ robust scaling
```

4. Stage 2 完整输入接口

附录区分了:

字段	实际角色
---	---
`z`	128 维预测内容
`flow_id`	对齐与稳定排序
`flow_start_timestamp_us`	时间顺序构造
`source_id`	source-host 关系
`destination_id`	destination/endpoint 关系
`split`	context policy 控制
`label`	训练与评估目标

并明确说明 IP 地址本身没有被编码成预测特征。

5. 完整排除字段

附录列出了所有未进入主要模型的字段, 包括:

- packet/flow identifiers;
- absolute timestamps;
- IP addresses 和 ports;
- TCP sequence/acknowledgement numbers;
- combined TCP flags;
- `l7\_proto`;
- `direction\_iat\_us`;
- `active\_std`;
- 所有 idle statistics;
- URG flow statistics;
- packet/flow labels。

从代码发现并写入附录的重要细节

Packet-length flow statistics 实际基于 payload length

`custom-out.c` 中:

```
static uint32_t GetCicPacketLen(const Packet *p)
{
    return (uint32_t)p->payload_len;
}
```

因此以下字段实际描述 payload-length aggregates, 而不是完整 IP packet length:

- `total\_length\_of\_fwd\_packets`
- `total\_length\_of\_bwd\_packets`
- directional packet-length max/min/mean/std
- overall packet-length statistics
- `average\_packet\_size`
- `avg\_fwd\_segment\_size`
- `avg\_bwd\_segment\_size`

Appendix A 已准确说明这一点。

`cwe\_flag\_count` 实际统计 CWR

CSV 字段名称是:

```
cwe_flag_count
```

但代码实际判断:

```
if (flags & TH_CWR)
    agg->cwe_count++;
```

因此附录写为:

> Legacy CSV name for the number of TCP packets carrying the CWR flag.

`min\_seg\_size\_forward` 实际来自 L4 header length

代码调用:

```
GetL4HeaderLen(p)
```

所以它并不是一般意义上的 payload segment size, 而是:

> minimum forward layer-4 header length

附录也按照实现而非字段名称进行了解释。

Active-period 阈值

代码定义：

```
#define CIC_ACTIVE_TIMEOUT_US 5000000ULL
```

因此 active period 以 5 秒 IAT gap 作为边界。Appendix A 已写明。

使用的代码依据

主要依据包括：

- [Stage 1 principal config](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/s1/C/0703/token_film_3/stage1_config_C.yaml:33)
- [preprocessing.py](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/s1/stage1/preprocessing.py:458)
- [data_io.py](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/s1/stage1/data_io.py:229)
- [export_embeddings.py](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/s1/stage1/export_embeddings.py)
- [Stage 2 data loader](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/s2/stage2/data_io.py)
- [Stage 2 context builder](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/s2/stage2/context.py)
- [custom-out.c](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/suricata-plugin/custom-out.c:241)

我采用 `s1/C/0703/token\_film\_3/stage1\_config\_C.yaml` 作为主要配置依据，因为其中 `max\_residual\_ratio=0.13` 与论文当前方法章节一致。

静态校验结果：

- 左右花括号一致；
- 缺失引用标签：0；
- 重复有效标签：0；
- Appendix A 已在 bibliography 前通过 `appendix` 和 `input` 接入。

用户 2026-08-05 16:55:47

这个appendix太多了。我只需要两个表格，Packet和Flow 所有field和Implementation meaning and unit before transformation。

请帮我修正上面的appendix

助手 2026-08-05 16:55:56

我会把 Appendix A 精简为只有两个 `longtable`：一个列出 Packet CSV 的全部 40 个字段，另一个列出 Flow CSV 的全部 77 个字段；每张表只保留 `Field` 和 `Implementation meaning and unit before transformation` 两列。原来的预处理、Stage 2 metadata、排除字段等附录内容都会移除。

助手 2026-08-05 16:58:09

已将 Appendix A 精简为仅包含两个表格：

1. Packet CSV 全部 40 个字段；
2. Flow CSV 全部 77 个字段。

每张表只有两列：

- `Field`
- `Implementation meaning and unit before transformation`

修改后的文件：

- [appendix_a_complete_features.tex](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/appendix_a_complete_features.tex)
- [已接入附录的论文](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/main_external_revision.tex)

已删除原附录中的：

- 预处理规则章节；
- Stage 2 metadata 表；
- excluded fields 表；
- predictor 分类说明；
- 独立时间编码章节；
- 额外说明性表格。

保留了一小段必要引言，解释两个表格是自定义 Suricata 模块输出的完整原始 schema，数值含义均为转换前的定义。

校验结果：

- Packet 字段行数：40；
- Flow 字段行数：77；
- 左右花括号一致；
- 缺失标签：0；
- 重复有效标签：0。

正文中的 Appendix 引用也已同步改为：

```
A field-level specification of the complete raw packet and flow
schemas, including implementation meaning and measurement units
before transformation, is provided in
Appendix~\ref{app:feature_specification}.
```

用户 2026-08-06 14:19:23

Files mentioned by the user:

appendix_a_complete_features.tex:

C:/Users/XiaoyanXiong/Downloads/appendix_a_complete_features.tex

main (1).tex: C:/Users/XiaoyanXiong/Downloads/main (1).tex

sources (1).bib: C:/Users/XiaoyanXiong/Downloads/sources (1).bib

My request for Codex:

你是一个经验丰富的学术编辑和硕士论文审阅专家，专精于检查学术论文的准确性、流畅性和严谨性。现在，我提供给你一篇完整的说是毕业论文latex。请你仔细阅读并分析整个论文，从以下几个方面进行全面检查和反馈：

- 1.语法和拼写错误：识别并列出所有语法错误、拼写错误、标点符号使用不当（包括标题中的符号，如冒号、破折号等），并建议修正。
- 2.表达流畅性：检查句子结构是否流畅、自然，是否存在awkward phrasing、冗余表达、模糊词汇或不连贯的段落过渡。针对每个问题，提供改进建议，使语言更清晰和学术化。
- 3.学术严谨性：评估内容的逻辑一致性、论证是否充分、术语使用是否准确和一致、引用格式是否规范（例如APA、MLA等标准）、数据和图表的准确性、避免主观偏见或未经证实的声明。如果有不严谨之处，指出并建议如何加强。
- 4.结构和格式问题：检查标题和子标题的格式一致性、章节组织是否合理、摘要、引言、

文献综述、方法论、结果、讨论和结论的部分是否完整和连贯。注意任何格式错误，如字体、间距或参考文献列表。

5. 整体建议：在检查结束后，提供一个总结，包括论文的强项、主要问题列表（按严重程度排序），以及总体改进建议。确保你的反馈具体、可操作，并引用论文中的具体位置（如页码、段落或句子）来支持你的评论。

请以结构化的格式输出你的反馈，例如使用编号列表或表格，便于我参考。

助手 2026-08-06 14:19:34

我会以你这次提供的 ``main (1).tex``、``appendix_a_complete_features.tex`` 和 ``sources (1).bib`` 为唯一审阅版本，不沿用之前文件的结论。先做全文结构、引用键、标签、数字和表格一致性的自动核查，再逐章进行语言与学术论证审阅；最后会给出按严重程度排序、带具体行号的完整报告。只审阅，不修改文件。

助手 2026-08-06 14:20:01

初步结构核查已经发现一个明确的高优先级格式问题：当前文件把 ``bibliography{sources}`` 放在 ``appendix`` 之前，因此附录会出现在参考文献之后；而你提供的 Bib 文件名是 ``sources (1).bib``，与正文调用的 ``sources`` 也不一致。除非编译目录中另有 ``sources.bib``，否则这会导致参考文献文件找不到。接下来我会继续检查全文的数字、术语、交叉引用和语言问题。

助手 2026-08-06 14:21:50

我会继续做交叉核对，重点检查三类“容易被语言润色掩盖”的问题：摘要与结果数字是否一致、因果/外部泛化等术语是否被证据支持，以及正文—附录—Bib 文件在编译和引用上的一致性。最终会把“必须修改”和“可选优化”分开列出。

助手 2026-08-06 14:26:22

外部测试部分出现了一个需要特别确认的证据链问题：正文把这些分数写成了“Stage 1 与 Stage 2 冻结模型共同进行外部评估”，但你之前提供的运行描述明确写的是“Stage1 external-test pairs”。我正在核对本地结果目录，看是否确实存在对应的外部 Stage 2 推理记录；如果没有，这会是提交前必须修正的核心问题。

助手 2026-08-06 14:34:40

总体结论

论文主体结构完整，方法描述较细，内部实验的数值基本自洽，英语写作质量也明显高于一般硕士论文初稿。不过，当前版本还不适合直接提交。

最严重的问题不是语法，而是外部测试的实验有效性：论文中报告的 CICIDS2017 和跨服务器测试成绩，与项目中明确标记为 ``leaky`` 的 Stage2 运行结果完全一致。这意味着部分外部测试样本进入了模型训练，不能再被称为独立外部测试。这一问题必须通过重新运行实验解决，不能只修改措辞。

由于当前环境没有完整的 ``mcs.sty``、图片资源和 LaTeX 编译器，以下位置以源文件行号为准，无法可靠给出最终 PDF 页码。

1. 必须修改的严重问题

1.1 外部测试结果存在数据泄漏

论文在 [main.tex:1223](C:/Users/XiaoyanXiong/Downloads/main.tex:1223) 声明：

> Stage1 and Stage2 checkpoints, preprocessing statistics, and threshold remain unchanged; no external test label is used for fitting...

但运行记录显示，论文中的外部测试成绩来自 `run\_stage2\_leaky.py`。

CICIDS2017

在 [0803B_external_Wednesday_workingHour_w01-08.ipynb:1974](C:/Users/XiaoyanXiong/Desktop/NIDS Transformer/ipynb/0803B_external_Wednesday_workingHour_w01-08.ipynb:1974) 调用了：

```
run_stage2_leaky.py
```

随后运行记录在第 2004 行明确警告，该脚本会引入 train/validation/test leakage；第 2055 行显示：

```
leaked_counts={'val': 26368, 'test': 10000}
```

即 w01 的 20,000 个外部测试样本中，有 10,000 个进入了训练。该 notebook 第 2542 行的 w01 指标与论文完全一致：

- Accuracy = 0.9478
- Macro-F1 = 0.9124926
- PR-AUC = 0.9088162

w02、w06、w07、w08 也分别通过同一个 `leaky` 脚本运行，论文中的指标与这些运行记录一致。

跨服务器 firewall 测试

在 [0727wensday.ipynb:4417](C:/Users/XiaoyanXiong/Desktop/NIDSTransformer/ipynb/0727wensday.ipynb:4417) 同样调用了 `run\_stage2\_leaky.py`。第 4499 行显示：

```
leaked_counts={'val': 26368, 'test': 19256}
```

即 38,513 个外部测试样本中，有 19,256 个进入了训练。

论文报告的 Macro-F1 = 0.90255、PR-AUC = 0.87713，准确对应 notebook 第 4940 行的泄漏结果。相反，同一个 notebook 中未使用 `leaky` 脚本的结果约为：

- Macro-F1 = 0.8072
- PR-AUC = 0.6943

但这个非泄漏结果似乎仍然属于 Scheme B，因此也不能直接作为论文最终的 Scheme C 外部测试结果。

必须采取的措施

在重新完成无泄漏实验以前，应暂时删除或注释以下内容：

- 摘要中的外部测试结论：[main.tex:57](C:/Users/XiaoyanXiong/Downloads/main.tex:57)
- 贡献列表中的外部验证声明：[main.tex:100](C:/Users/XiaoyanXiong/Downloads/main.tex:100)
- 外部协议描述：[main.tex:1220](C:/Users/XiaoyanXiong/Downloads/main.tex:1220)
- 外部结果表和讨论：[main.tex:1655](C:/Users/XiaoyanXiong/Downloads/main.tex:1655)
- 跨阶段总结中的外部结论：[main.tex:1716](C:/Users/XiaoyanXiong/Downloads/main.tex:1716)
- 结论中的外部泛化声明：[main.tex:1732](C:/Users/XiaoyanXiong/Downloads/main.tex:1732)

重新运行时需要确保：

1. 只在 `ar002\_et12\_20260511\_001` 上训练一次 Stage1 和 Stage2。
2. 使用论文主要模型 Scheme C，而不是为每个外部窗口重新训练 Scheme B。

3. 固定训练数据得到的预处理统计量。
4. 固定源验证集选择的分类阈值。
5. CICIDS2017和firewall标签绝不参与训练、阈值选择或超参数调整。
6. 每个外部数据集只执行推理。
7. 保存checkpoint哈希、配置文件、Git commit和完整运行命令。
8. 不再使用 `run\_stage2\_leaky.py` 生成论文结果。

当前这些泄漏结果最多只能作为 “negative-control experiment” 说明数据泄漏会造成多大的性能高估，不能放在主要外部测试表中。

1.2 CICIDS2017窗口选择标准与实际选择矛盾

论文在 [main.tex:240](C:/Users/XiaoyanXiong/Downloads/main.tex:240) 和 [main.tex:1225](C:/Users/XiaoyanXiong/Downloads/main.tex:1225) 表示选择 w01、w02、w06、w07、w08，是因为这些窗口满足label 1为少数类。

但实际八个窗口的正类比例为：

窗口	Label 1比例	Label 1是否少于Label 0	论文是否选择
---	---	---	---
w01	18.195%	是	是
w02	13.515%	是	是
w03	97.165%	否	否
w04	96.270%	否	否
w05	48.755%	是	否
w06	16.480%	是	是
w07	13.340%	是	是
w08	15.235%	是	是

因此，“Label 1少于Label 0”不能解释为什么排除w05。

建议采用以下方案之一：

- 最严谨：报告全部八个窗口的无泄漏结果。
- 或者预先定义明确阈值，例如“正类比例不高于20%”，并解释该阈值为什么在运行结果之前就已确定。
- 将w05列入附录中的排除窗口表，并明确给出排除原因。
- 避免根据已经看到的性能结果反向选择窗口，否则会产生选择偏差。

此外，“prevalence-compatible”并不准确。源数据正类比例约为3.945%，而选择的CICIDS窗口约为13.34%–18.20%，两者仅有“不平衡方向相同”，不能说prevalence相似。建议改为：

minority-positive windows

或者：

windows with the same class-imbalance direction as the source dataset

“Wednesday-workingHours was divided into eight windows”也不够准确。实际窗口是跨整个时间序列均匀抽取的、不重叠的20,000-flow窗口，窗口之间存在间隔。建议改为：

Eight evenly spaced, non-overlapping chronological windows of 20,000 flows were sampled across the capture.

1.3 外部实验不是论文主要Scheme C模型

外部实验 notebook 使用的是：

stage1_config_B_Both.yaml

也就是Scheme B，而论文主体结论强调Scheme C为完整模型。

因此即使消除了数据泄漏，也必须在以下两种做法中选择一种：

1. 使用Scheme C重新运行全部外部测试；这是最推荐的做法。
2. 明确将外部测试命名为“Scheme B representation-transfer experiment”，不能把它写成完整分层模型的外部泛化结果。

当前 [main.tex:1705](C:/Users/XiaoyanXiong/Downloads/main.tex:1705)

关于完整层次表示在外部数据中迁移的结论，证据不足。

1.4 外部标签与源标签的语义没有对齐

源数据中的Label 1来自Suricata alert-derived weak

labels，而CICIDS2017通常具有公开攻击标签。论文没有清楚说明外部数据最终使用的是：

- CICIDS2017官方攻击标签；
- 相同Suricata规则重新生成的标签；
- 还是其他二元映射。

这会直接影响“external generalisation”的含义。

建议在Dataset或Experimental Methodology中新增一张表：

数据集	原始标签来源	Label 0定义	Label 1定义	二元映射方法
---	---	---	---	---
Source capture	Suricata alerts	无匹配alert	匹配alert	当前规则集
CICIDS2017	需明确	需明确	需明确	需明确
Firewall capture	需明确	需明确	需明确	需明确

如果三者的Label 1语义不同，应使用：

transfer between related but non-identical detection targets

而不是直接宣称严格的跨数据集泛化。

2. 语法、拼写和表达修改

论文整体英语质量较好，不存在大面积语法错误。以下是应当修改的具体位置。

位置	当前问题	建议
---	---	---
[main.tex:57](C:/Users/XiaoyanXiong/Downloads/main.tex:57)	PR-AUC第一次出现没有定义	只在这里改为`PR-AUC (computed as Average Precision)`；后续全部继续使用`PR-AUC`
[main.tex:57](C:/Users/XiaoyanXiong/Downloads/main.tex:57)	`attack-class performance`与弱标签语义冲突	改为`positive-class performance`
[main.tex:69](C:/Users/XiaoyanXiong/Downloads/main.tex:69)	`cyber-security`不统一	改为`cybersecurity`
[main.tex:69](C:/Users/XiaoyanXiong/Downloads/main.tex:69)	普通名词不需要全部大写	`Network`

Intrusion Detection Systems`改为`network intrusion detection systems` |
 | [main.tex:94](C:/Users/XiaoyanXiong/Downloads/main.tex:94) | 写着 “three principal contributions” , 但后面有四项 | 改为`four principal contributions`, 或合并为三项 |
 | [main.tex:104](C:/Users/XiaoyanXiong/Downloads/main.tex:104) | 再次使用`attack-class` | 改为`positive-class` |
 | [main.tex:631](C:/Users/XiaoyanXiong/Downloads/main.tex:631) |
 标题使用美式`Artifacts`, 正文主要是英式英语 | 改为`Artefacts` |
[main.tex:1518](C:/Users/XiaoyanXiong/Downloads/main.tex:1518)	`most expensive run observed` 暗示经济成本, 但实际比较训练时间	改为`the longest reported Stage1 training run`
[main.tex:1703](C:/Users/XiaoyanXiong/Downloads/main.tex:1703)	`demonstrate meaningful transfer` 主观且过强	无泄漏实验后改为`show the observed transfer performance`
[main.tex:1705](C:/Users/XiaoyanXiong/Downloads/main.tex:1705)	`Cross-server degradation` 缺少完全可比的参考基线	改为`The cross-server error profile...`
[appendix_a_complete_features.tex:4](C:/Users/XiaoyanXiong/Downloads/appendix_a_complete_features.tex:4)	`standard-deviation` 作为名词不应加连字符	改为`standard deviation`; 若列举多个统计量, 使用复数

Appendix开头建议写成:

```
For length- and timing-based fields, the implementation records
means, standard deviations, sample variances, minima, and maxima
before transformation.
```

3. 学术严谨性问题

3.1 “Causal” 表述可能造成误解

论文在 [main.tex:1064](C:/Users/XiaoyanXiong/Downloads/main.tex:1064) 已经诚实承认:

- Stage2上下文只保证按照flow start time排序;
- 前一个flow的完整embedding在目标flow开始时不一定已经可用;
- 没有强制执行 `previous\_flow\_end <= target\_flow\_start`。

因此, 这并不是严格在线部署意义下的causality。

但摘要、贡献、章节标题和结果讨论中仍多次使用:

- causal history;
- causal Stage2;
- causal target-query;
- Causal Inter-Flow Context。

建议统一改为:

```
start-time-ordered, label-free inter-flow context
```

如果必须保留`causal`, 第一次出现时应写成:

```
causal with respect to the ordering of flow start times, rather than
strict online availability
```

否则读者容易理解为模型在目标决策时绝不使用未来才完成的flow信息。

3.2 单次随机种子不足以支撑稳定性结论

论文已经在局限性中承认只使用一个固定seed, 这是好的。但正文中应避免:

- robust improvement;
- consistently superior;
- statistically reliable;
- demonstrate conclusively.

更合适的是：

the best observed result under the reported fixed-seed protocol

建议至少对主要Scheme B/C和Stage2 best configuration运行3–5个随机种子，报告：

mean $\pm$ standard deviation

如果确实无法重跑，应明确称结果为descriptive comparison，而不是统计显著性比较。

3.3 实验复现信息不完整

[main.tex:1449](C:/Users/XiaoyanXiong/Downloads/main.tex:1449) 已经指出缺少：

- 软件包版本快照；
- Suricata版本；
- ruleset snapshot；
- custom plugin revision；
- PCAP checksum。

这不是单纯的小限制，因为源标签来自Suricata。没有规则集版本就无法重建相同标签。

建议在附录或代码仓库提供：

- Python、PyTorch、CUDA和scikit-learn版本；
- GPU型号；
- Suricata版本；
- 规则集来源和日期；
- 自定义插件Git commit；
- 配置文件SHA-256；
- 数据manifest和PCAP哈希；
- 最终checkpoint哈希；
- 完整训练、验证和外部推理命令。

另外，论文Stage1 sampler target写为10%，但工作区候选Scheme C配置中出现了`0.09`。需要核对最终实际配置，避免论文和代码不一致。

3.4 内部实验数值检查

内部主要数值在算术上基本正确：

- $405,254 + 16,644 = 421,898$ ；
- 正类比例约3.945%；
- 类别比例约24.35:1；
- 训练、验证、测试划分合计421,898；
- Stage2 manifest $80,860 + 3,520 = 84,380$ ；
- Scheme C提升至Stage2最佳结果的百分点计算正确；
- FPR相对下降约34.2%，计算正确。

CICIDS和firewall混淆矩阵也与表中指标相符。问题不是计算错误，而是这些外部指标来自泄漏实验，因此不能作为有效外部测试证据。

4. 结构和格式问题

4.1 Appendix与参考文献的顺序

当前文件末尾为：

```
\bibliographystyle{unsrt}
\bibliography{sources}

\appendix
\input{appendix_a_complete_features}
```

即参考文献在Appendix之前。不同学院要求可能不同，但多数计算机论文模板会采用：

```
\appendix
\input{appendix_a_complete_features}

\bibliographystyle{unsrt}
\bibliography{sources}
```

应以学院的official thesis handbook为最终标准。如果没有明确要求，建议把Appendix放到Bibliography前面。

4.2 Chapter不强制换页

前言区 [main.tex:19](C:/Users/XiaoyanXiong/Downloads/main.tex:19) 使用了：

```
\titleclass{\chapter}{straight}
```

这会改变标准`report`类中chapter从新页开始的行为。对于硕士论文，这是比较不寻常的格式。建议检查学院模板；如果没有明确允许，恢复chapter从新页开始。

4.3 文档类型可能不准确

[main.tex:47](C:/Users/XiaoyanXiong/Downloads/main.tex:47) 使用：

```
\doctype{Final Project}
```

如果这是硕士毕业论文，应核对学校要求是否应写：

```
Master's Thesis
```

或：

```
MSc Thesis
```

不能仅根据口头称呼判断，必须以项目手册为准。

4.4 可能缺少的前置部分

当前论文包含摘要、正文、参考文献和Appendix，但未看到：

- List of Figures;
- List of Tables;
- List of Abbreviations;
- Declaration of Originality;

- Acknowledgements.

其中哪些是必需项取决于学院规定。论文中图表和缩写较多，因此至少建议加入：

```
\listoffigures
\listoftables
```

缩写表也会提高可读性，尤其是NIDS、IDS、PR-AUC、FPR、TPR、MLP、FiLM等。

4.5 图表引用和视觉格式

两个有标签的表没有在正文中明确交叉引用：

```
- `tab:experimental_environment`
- `tab:results_external_errors`
```

建议在正文中添加类似：

```
Table~\ref{tab:experimental_environment} summarises the experimental
hardware and software environment.
```

全文大量使用[H]强制浮动位置，并多次使用\resizebox。可能造成：

- 页面底部大面积空白；
- 表格字体过小；
- 图表跨页不自然。

由于当前提供的文件包缺少mcs.sty和部分图片，我无法编译并进行最终页面视觉检查。提交前必须在完整项目中检查：

- overfull/underfull box警告；
- 表格字号；
- 图注与正文间距；
- 页面孤行；
- 章节是否从新页开始；
- 图像分辨率；
- 目录和页码。

5. 引用和BibTeX检查

5.1 自动检查结果

- 正文使用了约52个不同引用键。
- `sources.bib`包含60条文献。
- 没有发现缺失引用键。
- 没有发现重复BibTeX键。
- 有8条Bib记录未被正文引用：

```
Alwhbi2024EncryptedSurvey
Garcia2023HighSpeedIDS
Kanimozhi2024MLIDS
Kim2016LSTM
NVIDIAT4Datasheet
Ponniah2023DLIDS
Tan2025ContrastiveSurvey
Zhang2025LLMDetection
```

BibTeX默认不会打印未引用条目，但建议清理或确认是否应在正文中引用。

5.2 参考文献风格

当前使用：

```
\bibliographystyle{unsrt}
```

这是按引用出现顺序排列的数字风格，不是APA或MLA。它未必错误，计算机专业经常使用数字引用，但需要确认学院是否要求IEEE、ACM、APA或Harvard。

5.3 发现的元数据错误

以下条目需要重点修正：

Bib位置	问题
[sources.bib:204](C:/Users/XiaoyanXiong/Downloads/sources.bib:204)	
`Deng2023FlowTopology`作者列表错误；正确作者包括Xiaoheng Deng、Jincai Zhu、Xinjun Pei、Lan Zhang、Zhen Ling和Kaiping Xue。[论文记录](https://digitalcommons.mtu.edu/michigantech-p/16478/)	
[sources.bib:85](C:/Users/XiaoyanXiong/Downloads/sources.bib:85)	Hozouri论文期刊应为`Discover Artificial Intelligence`，不是`Discover Applied Sciences`。[Springer DOI](https://doi.org/10.1007/s44163-025-00578-1)
[sources.bib:56](C:/Users/XiaoyanXiong/Downloads/sources.bib:56)	Sharma条目使用`and others`且标题被缩短；应补全作者和完整标题。[DOI](https://doi.org/10.1016/j.comnet.2024.110984)
[sources.bib:215](C:/Users/XiaoyanXiong/Downloads/sources.bib:215)	Zhong条目缺少作者Zeshui Xu
[sources.bib:335](C:/Users/XiaoyanXiong/Downloads/sources.bib:335)	MFT条目缺少作者Xianjin Fang。[DOI](https://doi.org/10.1016/j.cose.2024.104174)
[sources.bib:242](C:/Users/XiaoyanXiong/Downloads/sources.bib:242)	Goldschmidt条目缺少卷号、文章号和DOI；应为`Computers & Security`，156, 104510。[DOI](https://doi.org/10.1016/j.cose.2025.104510)
[sources.bib:174](C:/Users/XiaoyanXiong/Downloads/sources.bib:174)	Long条目缺少DOI `10.1186/s13677-023-00574-9`。[Springer](https://link.springer.com/article/10.1186/s13677-023-00574-9)
[sources.bib:196](C:/Users/XiaoyanXiong/Downloads/sources.bib:196)	ET-BERT缺少DOI和完整会议名称。[论文页面](https://arxiv.org/abs/2202.06335)
[sources.bib:41](C:/Users/XiaoyanXiong/Downloads/sources.bib:41)	FlowTransformer缺少卷号241和文章号122564。[DOI](https://doi.org/10.1016/j.eswa.2023.122564)

此外，应使用花括号保护标题中的缩写和专有名词，例如：

```
title = {{NIDS}: ...}  
title = {... {IoT} ...}  
title = {... {DDoS} ...}  
title = {... {Suricata} ...}
```

Suricata在线文档条目还应加入具体文档版本和访问日期，而不是只写滚动URL和年份。

6. 论文的主要强项

论文并不是需要全面重写。以下部分做得很好：

1. 研究问题、贡献、方法、实验和结论之间总体对应清楚。
2. Stage1和Stage2的职责划分明确。
3. 对弱标签、Suricata规则盲区以及“未触发alert不等于安全”的说明很严谨。
4. 使用Macro-F1、PR-AUC、类别F1和FPR评价不平衡数据，指标选择合理。

5. 清楚区分Stage1 manifest和完整Stage2 manifest，避免直接进行不公平比较。
6. 内部实验的表格、混淆矩阵和派生指标基本自洽。
7. 对缺失软件快照、单随机种子、非端到端延迟等限制进行了主动披露。
8. Appendix中的Packet和Flow字段表总体清晰，基本满足“字段名称 + 变换前实现含义和单位”的目标。

7. 推荐修改顺序

按严重程度，建议严格依照以下顺序处理：

1. 立即停止使用所有`run\_stage2\_leaky.py`结果作为外部测试证据。
2. 用一个固定的Scheme C checkpoint重新执行无泄漏外部推理。
3. 修正CICIDS窗口选择标准，最好报告全部八个窗口。
4. 增加三个数据集的标签来源和二元映射说明。
5. 修正“causal”定义和全文术语。
6. 补充配置、checkpoint、规则集和软件版本信息。
7. 修正BibTeX元数据和引用风格。
8. 完成少量英语表达修改，尤其是贡献数量、PR-AUC第一次定义和positive-class术语。
9. 根据学院模板调整Appendix、Bibliography、chapter分页和前置页面。
10. 在完整LaTeX项目中重新编译，检查所有图表、交叉引用和页面排版。

综上，论文内部方法与写作基础是扎实的；真正阻碍提交的是外部测试实验链条。只要重新获得严格无泄漏的外部结果，并相应收紧结论，论文的可信度会有实质性提升。本次检查未修改任何源文件。